

固定有限モノイド助言を用いたファンアウト有界線形 MCFG の正例データ学習

栗山 貴之
独立研究者（東京）

概要

本論文では、固定された有限状態の補助情報の下で、ファンアウト有界な線形多重文脈自由言語の意味論的部分クラスを正例データから学習する問題を研究する。補助情報は、学習開始前に与えられ、正例テキストから推論されることのない、明示的な有限モノイド準同型 $h: \Sigma^* \rightarrow M$ である。

簡約された作業形二分・線形・非消去 MCFG 表示に対して、名前付き文コンテキストと成分ごとの h -型を用いて、 (f, h) -タプル代入可能性を定義する。任意の固定されたファンアウト上界 f と固定された明示的準同型 h に対し、正準的な集合駆動学習器を構成する。証明では、証人表示の出力型精密化と、表示相対的な有限特徴標本によって露出される具体的な共有文コンテキストを用いる。精密化は成分ごとの出力型を記録し、標本は成分配置を復元し代入を保護するために必要な情報を与える。対象が要求される作業形表示をもち、意味論的な (f, h) -代入可能性の仮定を満たすならば、特徴標本を含む任意の正例標本から得られる仮説は、対象言語を厳密に生成する。したがって、各固定観測ファイバーは正例データから極限同定可能である。固定された (f, h) に対し、有限標本 K に対応する仮説は、出力サイズを含めて時間 $\|K\|_+^{O(f)}$ で構成可能である。

さらに、観測助言の境界を決定する。モノイドの大きさに固定上界があるすべての観測は、一つの有限直積準同型へまとめることができ、同定可能性を保つ。一方、すべての有限観測にわたる非有界集合は、正例データから同定できない。最後に、無限メンバー核基準によって、コピー言語を含むいくつかの言語を、すべての有限観測ファイバーから排除する。したがって固定有限モノイド助言は、MCFL 全体を再構成するのではなく、その内部に真の学習可能領域を切り出す。

キーワード：文法推論、多重文脈自由文法、正例データ、極限同定、有限モノイド、タプル代入可能性

1 序論

Gold の定理は、広い言語クラスが正例データだけでは同定できないことを示している [9]。正例データからの学習可能性を回復する有効な方法の一つは、分布上の制約を課すことである。すなわち、観測された部分文字列、あるいはより一般には観測されたタプルは、それらを受理するコンテキストが十分に制御された仕方で一致するとき、安全に置換できると考える。この見方は、Clark と Eyraud の代入可能文脈自由言語 [3]、Yoshinaka による弱文脈依存言語の多次元代入可能性に関する結果 [20, 21, 22]、さらに並列文脈自由文法および多重文脈自由文法の分布学習に関する後続研究 [4, 5] の基礎にある。これに関連する正例データ学習可能性は、制限された範疇文法にも現れる

[12]。MCFG および関連形式体系を動機づける弱文脈依存文法の背景については、[15, 18, 19, 11] を参照されたい。

本論文は、この考え方の型付き版を、ファンアウト有界な作業形多重文脈自由文法 (MCFG) に対して研究する。本結果は、文脈自由言語に対する固定有限モノイド型付き分布学習 [13] の弱文脈依存版とみなすことができる。型情報は、固定された明示的有限モノイド準同型 $h: \Sigma^* \rightarrow M$ によって与えられる。この準同型はテキストから推論されない。それは観測助言、すなわち、たとえば正則包絡や粗い有限状態注釈を記録しうる有限インターフェースである。本論文で「助言」という語は、テキストより前に与えられる固定補助情報という学習理論上の意味でのみ用い、非一様計算量理論における助言クラスを意味しない。したがって学習器は助言相対的である。学習器は正例から対象言語を学習するが、観測インターフェース自体はあらかじめ固定される。すべての結果は、ファンアウトが有界で、簡約された作業形二分・線形・非消去 MCFG 表示をもつ言語について述べる。任意の MCFG に対する正規形定理を用いることも、主張することもない。

■何を学習し、何を学習しないのか。 学習器は、対象言語の正例と固定有限準同型 h を受け取る。対象文法、導出オラクル、負例、所属質問、あるいは決定可能な入力としての意味論的仮定は受け取らない。定理が述べるのは、未知の対象が固定ファイバー $C_{f,h}^{\text{mcf}}$ に属するならば、有限個の正例標本だけで正準的集合駆動学習器が厳密な対象言語へ安定する、ということである。正例データから h 自体を発見できるとは述べない。また、任意の MCFG が正例データから同定可能であるとも述べない。

対象条件を (f, h) -タプル代入可能性と呼ぶ。MCFG の非終端記号は単一の文字列ではなくタプルを導出するため、関係するコンテキストは複数の穴をもつ名前付き文コンテキストである。アリティが高々 f の二つのタプルを同一視できるのは、各成分の h -型が等しく、かつ少なくとも一つの受理文コンテキストを共有するときに限られる。意味論的仮定は、そのときすべての受理コンテキストが一致することを要求する。これは対象言語に対する意味論的仮定であり、入力文法に対する決定可能な構文論的仮定ではない。

本論文の主要な貢献は次のとおりである。

- (i) 簡約された作業形二分・線形・非消去 MCFG 表示をもち、意味論的な (f, h) -タプル代入可能性を満たす言語に対して、固定観測ファイバー $C_{f,h}^{\text{mcf}}$ を定義する。
- (ii) 各固定 f と固定された明示的有限準同型 h に対し、正準的正例データ学習器を構成し、表示相対的な有限特徴標本からの厳密な言語再構成を証明する。学習器が保存するのは観測タプル値だけであり、成分配置は具体的な証人付き分割から復元され、代入は実際に共有された文コンテキストによって保護される。
- (iii) 構成時間とデータサイズを区別する。与えられた有限標本に対応する仮説は、出力サイズを含めて時間 $\|K\|_+^{O(f)}$ で構成可能である。多項式露出上界をもつ部分クラスでは多項式サイズの特徴標本が得られるが、対象クラス全体についてそのような上界は主張しない。
- (iv) 有限観測が真正の助言であることを証明する。モノイドサイズに固定上界があるすべての観測の和集合は一つの直積準同型へまとめられる一方、すべての有限準同型にわたる非有界な集合は正例データから同定できない。
- (v) 表示に依存しないメンバー核排除基準を与え、文脈自由な傾き和言語とコピー言語に適用する。したがって固定観測ファイバーは、MCFL 階層全体の言い換えではなく、その真の助言

相対的部分領域をなす。

第 2 節で主要定理群を述べる。第 3 節では学習論的および文法論的定義を与え、第 4 節では標準的な同期例を記す。第 5 節と第 6 節では学習器を定義し、厳密同定を証明する。第 7 節では、固定パラメータの仮説構成上界と、多項式データに必要な露出条件を分離する。第 8 節では、有界／非有界の観測助言境界とメンバー核による排除を証明する。第 9 節では、本結果を型なし分布条件と比較する。付録 付録 A では、意味論的仮定の非実効性を記す。

2 主要結果

本節では、技術的展開に先立って主要定理群を述べる。証明は第 5 節から第 8 節に与える。以下で用いる作業形表示の仮定は、すべて定義 3.10 のものと正確に一致しており、任意の MCFG に対する正規化定理を用いているわけではない。

定理 2.1 (厳密再構成 (概略)). ファンアウト上界 f と明示的有限準同型 $h: \Sigma^* \rightarrow M$ を固定する。 G をファンアウト高々 f の簡約された作業形二分・線形・非消去 MCFG とし、 $L = L(G)$ が (f, h) -タプル代入可能であると仮定する。このとき、表示相対的な有限特徴標本 $S_G \subseteq L$ が存在し、 $S_G \subseteq K \subseteq L$ を満たすすべての有限 K に対して、正準学習器は言語がちょうど L である文法を返す。

この主張は定理 6.8 として証明され、系 6.10 が極限同定を与える。

定理 2.2 (仮説構成 (概略)). 固定された f と固定された明示的 h に対し、有限標本 K に対応する正準仮説は、出力サイズを含めて時間 $\|K\|_+^{O(f)}$ で構成可能である。これは手元の標本からの構成上界であり、それだけで対象クラス全体に対する多項式データ定理を意味するものではない。

構成上界は定理 7.1 で証明し、多項式データの正確な境界は命題 7.3 に記す。

定理 2.3 (観測助言の境界 (概略)). 任意の固定アルファベット Σ 、ファンアウト上界 f 、モノイドサイズ上界 k に対し、濃度高々 k のモノイドへの準同型で定義されるすべてのファイバーの和集合は、正例データから同定可能である。これに対し、サイズ上界を設けず、すべての有限観測準同型にわたって取った和集合は、正例データから同定できない。

二つの部分は、それぞれ定理 8.9 と定理 8.6 である。

定理 2.4 (有限観測による排除 (概略)). ある言語の要素がもつアリティの受理文コンテキスト分布の指数が無限ならば、その言語はどの固定有限観測ファイバーにも属さない。とくに、コピー言語はすべてのそのようなファイバーの外にある。

これは定理 8.12 と命題 8.14 を合わせたものである。

3 準備と対象クラス

3.1 正例データ学習

定義 3.1 (テキストと同定). $L \subseteq \Sigma^*$ のテキストとは、 L の各要素が少なくとも一度は現れる、 L の要素からなる無限列 $(w_1, w_2, \dots)$ である。学習器とは、各有限接頭辞を仮説文法へ写す計算可能関数である。学習器がクラス $\mathcal{C}$ を正例データから極限同定するとは、任意の $L \in \mathcal{C}$ と任意の L のテキストに対して、ある n_0 が存在し、段階 n_0 以降に出力されるすべての仮説の言語が L になることをいう。

以下の学習器は順序に依存しないので、有限テキスト接頭辞をその有限集合 $K \subseteq L$ と同一視する。

定義 3.2 (特徴標本). 学習器 $\mathcal{A}$ と対象言語 L に対し、有限集合 $S \subseteq L$ が特徴標本であるとは、 $S \subseteq K \subseteq L$ を満たすすべての有限 K に対して $L(\mathcal{A}(K)) = L$ となることをいう。

定義 3.3 (正例標本サイズ). 有限集合 $K \subseteq \Sigma^*$ に対して、 $\|K\|_+ := \sum_{w \in K} \max(1, |w|)$ と定める。

因子 $\max(1, |w|)$ は、空語が許される場合に標本サイズが退化して 0 になるのを防ぐためだけのものである。以下の作業形非消去設定では、生成される非空の例が主要な場合である。

定義 3.4 (多項式時間および多項式データ). *de la Higuera* の特徴標本の観点 [6, 7] に従い、固定された外部パラメータの下で、表示クラスが多項式時間および多項式データで同定されるとは、次を満たす多項式 p, q が存在することをいう。すなわち、証人表示 G をもつ各対象は、正例サイズが高々 $p(|G|)$ の特徴標本をもち、任意の有限標本 K に対する学習器の仮説は、出力サイズも含めて高々 $q(\|K\|_+)$ 時間で構成できる。多項式データの部分は表示相対的である。つまり上界は、言語の標準的最小記述ではなく、選ばれた証人表示に対して測られる。

注意 3.5 (一様ではなく、スライスごとの多項式性). 本論文を通じて、「多項式時間」と「多項式データ」は、外部パラメータに関してスライスごとに理解する。すなわち、固定された各 f と固定された各 h に対して、次数がそれらのパラメータに依存してよい多項式上界を要求する。具体的な構成時間は $\|K\|_+^{O(f)}$ である。これは、外部パラメータを固定した *de la Higuera* の多項式基準を固定パラメータ的に読むものであり、 f に一様な単一の多項式を主張するものではない。 f に一様な上界は、主張も使用もしない。

本論文で用いる極限的正しさの概念は Gold 同定 [9] であり、特徴標本とは、集合駆動学習器を安定させる有限十分集合である。したがって「多項式時間および多項式データ」という用語は、別の学習モデルを意味するのではなく、正例データ同定を *de la Higuera* 型に多項式的に強化したものである。Angluin の厳密学習モデル [2] は、アルゴリズム学習における関連する画期的成果としてのみ引用する。本論文の学習器は、質問も反例も受け取らない。

補題 3.6 (有限十分標本から同定が従う). $\mathcal{A}$ を計算可能で順序に依存しない学習器とする。各 $L \in \mathcal{C}$ に対して有限集合 $S_L \subseteq L$ が存在し、 $S_L \subseteq K \subseteq L$ ならば $L(\mathcal{A}(K)) = L$ になると仮定す

る。このとき、 $\mathcal{A}$ は $\mathcal{C}$ を正例データから極限同定する。

証明. L の任意のテキストにおいて、有限個の語からなる S_L の全要素は、ある段階 n_0 までにすべて出現する。それ以後の任意の接頭辞標本は L に含まれ、かつ S_L を含むので、その段階以降の仮説言語は常に L である。 $\square$

3.2 有限モノイドによる型付け

定義 3.7 (明示的有限準同型). 有限モノイド M へのモノイド準同型 $h: \Sigma^* \rightarrow M$ が明示的であるとは、 M の積表と、各 $a \in \Sigma$ に対する値 $h(a)$ が与えられていることをいう。タプル $\vec{w} = (w_1, \dots, w_d)$ に対して、 $h^{(d)}(\vec{w}) := (h(w_1), \dots, h(w_d)) \in M^d$ と書く。

定義 3.8 (有限観測準同型の細分). $h: \Sigma^* \rightarrow M$ と $h': \Sigma^* \rightarrow M'$ を明示的有限準同型とする。 $h = \pi \circ h'$ を満たすモノイド準同型 $\pi: M' \rightarrow M$ が存在するとき、 h' は h を細分するといい、 $h \preceq h'$ と書く。

命題 3.9 (観測準同型の細分に関する単調性). $h \preceq h'$ であり、 L が (f, h) -タプル代入可能ならば、 L は (f, h') -タプル代入可能である。したがって、 $h \preceq h'$ を満たす任意の明示的有限準同型の組に対して、

$$\mathcal{C}_{f,h}^{\text{mcf}} \subseteq \mathcal{C}_{f,h'}^{\text{mcf}}.$$

証明. $h = \pi \circ h'$ を満たす $\pi: M' \rightarrow M$ をとる。 $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ であり、 $\vec{x}, \vec{y}$ が受理するアリティ d の文コンテキストを一つ共有すると仮定する。各成分に π を適用すれば、 $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ を得る。したがって、 L の (f, h) -タプル代入可能性により、 $\mathcal{D}_L^{(d)}(\vec{x}) = \mathcal{D}_L^{(d)}(\vec{y})$ である。これはまさに (f, h') -条件である。同じ証人作業形表示をそのまま用いられるので、クラスの包含も従う。 $\square$

有限モノイドは、本論文では固定された外部型付け装置としてのみ用いる。背景については Pin [16] を参照されたい。典型例としては、正則制御言語の遷移モノイド、正則近似の構文準同型、外部の構文解析器または形式体系が与える有限状態注釈などがある。以下の学習器は、そのような明示的準同型を固定パラメータの一部として仮定する。とくに、 h が正則包絡の遷移準同型である場合、学習器にはその正則包絡が有限形式で与えられていることになる。これは有用ではあるが自明でない助言である。以下の定理はその助言に相対的であり、正例データから助言自体を発見する問題を解くものではない。

3.3 作業形 MCFG 表示

定義 3.10 (二分・線形・非消去の作業形 MCFG). 二分・線形・非消去の作業形多重文脈自由文法とは、組 $G = (V, \Sigma, P, S, \mu)$ であって、 V は有限非終端記号集合、 Σ は有限終端アルファベット、 $S \in V$ は開始記号、 $\mu: V \rightarrow \mathbb{N}_{>0}$ は $\mu(S) = 1$ を満たすファンアウト写像であるものをいう。規則は次のいずれかの形をもつ。

- (i) 開始規則 $S \rightarrow A$ 。ただし $A \neq S$ かつ $\mu(A) = 1$ である。
- (ii) 終端規則 $A \rightarrow (a)$ 。ただし $A \neq S$ 、 $a \in \Sigma$ 、 $\mu(A) = 1$ である。

(iii) 二分規則

$$\rho: A \rightarrow (\alpha_1, \dots, \alpha_e)(B, C).$$

ただし $A \neq S$ 、 $e = \mu(A)$ 、 $\mu(B) = d_B$ 、 $\mu(C) = d_C$ であり、各 α_i は

$$\Sigma \cup \{x^1, \dots, x^{d_B}, y^1, \dots, y^{d_C}\}$$

上の語である。また各変数 $x^1, \dots, x^{d_B}, y^1, \dots, y^{d_C}$ は、タプル全体 $(\alpha_1, \dots, \alpha_e)$ にちょうど一度ずつ現れる。

この表示は開始記号分離型である。すなわち、左辺が S である規則は開始規則だけであり、二分規則の右辺の子として S が現れることはない。

二分規則

$$\rho: A \rightarrow (\alpha_1, \dots, \alpha_e)(B, C)$$

をとる。ただし、

$$e = \mu(A), \quad d_B = \mu(B), \quad d_C = \mu(C)$$

とする。

この規則に付随する変数集合を

$$X_B := \{x^1, \dots, x^{d_B}\}, \quad Y_C := \{y^1, \dots, y^{d_C}\}$$

とし、

$$\Gamma_\rho := \Sigma \uplus X_B \uplus Y_C$$

とおく。各

$$\alpha_\ell \in \Gamma_\rho^* \quad (1 \leq \ell \leq e)$$

を規則 ρ の**テンプレート成分**と呼び、そのタプル

$$\alpha_\rho := (\alpha_1, \dots, \alpha_e) \in (\Gamma_\rho^*)^e$$

を規則 ρ の**テンプレートタプル**と呼ぶ。

タプル

$$\vec{u} = (u_1, \dots, u_{d_B}) \in (\Sigma^*)^{d_B}, \quad \vec{v} = (v_1, \dots, v_{d_C}) \in (\Sigma^*)^{d_C}$$

に対して、写像

$$\sigma_{\vec{u}, \vec{v}}: \Gamma_\rho \rightarrow \Sigma^*$$

を

$$\begin{aligned} \sigma_{\vec{u}, \vec{v}}(a) &:= a & (a \in \Sigma), \\ \sigma_{\vec{u}, \vec{v}}(x^i) &:= u_i & (1 \leq i \leq d_B), \\ \sigma_{\vec{u}, \vec{v}}(y^j) &:= v_j & (1 \leq j \leq d_C) \end{aligned}$$

によって定める。

この写像を語へ一意に準同型拡張して得られる写像を

$$\hat{\sigma}_{\vec{u}, \vec{v}}: \Gamma_\rho^* \rightarrow \Sigma^*$$

とする。規則 ρ を $\vec{u}, \vec{v}$ に適用した結果を

$$\rho(\vec{u}, \vec{v}) := (\hat{\sigma}_{\vec{u}, \vec{v}}(\alpha_1), \dots, \hat{\sigma}_{\vec{u}, \vec{v}}(\alpha_e)) \in (\Sigma^*)^e$$

と定義する。これが二分規則の同時代入による意味論である。

各非終端記号 $A \in V$ のタプル言語

$$L_A(G) \subseteq (\Sigma^*)^{\mu(A)}$$

は、次の条件を満たす最小の族として定義する。

(i) 終端規則 $A \rightarrow (a)$ が存在するならば、

$$(a) \in L_A(G).$$

(ii) 二分規則

$$\rho: A \rightarrow (\alpha_1, \dots, \alpha_e)(B, C)$$

が存在し、

$$\vec{u} \in L_B(G), \quad \vec{v} \in L_C(G)$$

ならば、

$$\rho(\vec{u}, \vec{v}) \in L_A(G).$$

(iii) 開始規則 $S \rightarrow A$ が存在し、

$$\vec{w} \in L_A(G)$$

ならば、

$$\vec{w} \in L_S(G).$$

文法 G が生成する文字列言語を

$$L(G) := \{w \in \Sigma^* \mid (w) \in L_S(G)\}$$

と定義する。開始記号のファンアウトは $\mu(S) = 1$ なので、必要に応じて $L_S(G)$ と $L(G)$ を同一視する。

非終端記号 A が**生成的**であるとは、

$$L_A(G) \neq \emptyset$$

であることをいう。また、非終端記号依存グラフにおいて、開始記号 S から A への有向路が存在するとき、 A は S から**到達可能**であるという。ここで、開始規則 $S \rightarrow A$ に対して辺 $S \rightarrow A$ を置き、二分規則

$$A \rightarrow (\alpha_1, \dots, \alpha_e)(B, C)$$

に対して辺 $A \rightarrow B$ および $A \rightarrow C$ を置く。

すべての非終端記号が S から到達可能であり、かつ生成的であるとき、文法 G は**簡約**されているという。

注意 3.11 (作業形の適用範囲と、主張しないこと). 定義 3.10 は、学習器および特徴標本の証明で用いる表示モデルを固定する。このような各表示は、Seki ら [17] の意味で標準的な *MCFG* 表示である。しかし本論文では、任意の標準 *MCFG* を、学習定理に関係するすべてのパラメータを保存しつつ、この厳密な作業形へ実効的に変換できるとは主張しない。

開始記号分離の規約は無害であり、新しい開始記号を導入すれば強制できる。これに対して、二分性・線形性・非消去性は、本論文における真正の表示上の仮定である。したがって定理は、この作業形で簡約表示をもち、意味論的な (f, h) -タプル代入可能性の仮定を満たす言語に適用される。

この制限は意図的である。有限標本中で観測される二分証拠を、学習器が再構成する二分規則と対応させるためである。より一般のランク、消去規則、明示的な ε -生成を扱うには追加の記帳が必要であり、それらは本論文の主張には含まれない。

3.4 文コンテキストとタプル分布

定義 3.12 (文コンテキスト). アリティ d の文コンテキストとは、

$$E = u_0 \square_{\sigma(1)} u_1 \cdots \square_{\sigma(d)} u_d$$

の形の語である。ここで σ は $\{1, \dots, d\}$ の置換、各 $u_i \in \Sigma^*$ であり、各名前付き穴 $\square_i$ はちょうど一度現れる。 $\vec{w} = (w_1, \dots, w_d)$ に対して、各 $\square_i$ に w_i を代入して得られる文字列を $E[\vec{w}]$ と書く。

後に現れる MCFG 規則のテンプレート成分は空であってよい。空のタプル成分が標本語の内部で観測されるとき、それを、同一切断位置にある局所順序を固定した切断位置で表現する。これは具体的出現を列挙するための記帳にすぎない。

定義 3.13 (タプル分布). $d \geq 1$ とする。 $L \subseteq \Sigma^*$ および $\vec{x} \in (\Sigma^*)^d$ に対して、

$$\mathcal{D}_L^{(d)}(\vec{x}) := \{E \mid E \text{ はアリティ } d \text{ の文コンテキストであり } E[\vec{x}] \in L\}$$

と定義する。アリティが明らかなき場合は $\mathcal{D}_L(\vec{x})$ と書く。

定義 3.14 ((f, h) -タプル代入可能性). $f \geq 1$ とし、 $h: \Sigma^* \rightarrow M$ を明示的有限モノイド準同型とする。言語 $L \subseteq \Sigma^*$ が (f, h) -タプル代入可能であるとは、任意の $1 \leq d \leq f$ と任意の $\vec{x}, \vec{y} \in (\Sigma^*)^d$ に対して、 $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ かつ $\mathcal{D}_L^{(d)}(\vec{x}) \cap \mathcal{D}_L^{(d)}(\vec{y}) \neq \emptyset$ ならば、 $\mathcal{D}_L^{(d)}(\vec{x}) = \mathcal{D}_L^{(d)}(\vec{y})$ となることをいう。

$d = 1$ の場合、文コンテキストは通常の両側コンテキスト $u \square_1 v$ である。したがって定義 3.14 は、通常の固定 h 両側代入可能性条件に一致する。

定義 3.15 (対象クラス). $f \geq 1$ と明示的有限モノイド準同型 h を固定する。クラス $\mathcal{C}_{f,h}^{\text{mcf}}$ は、次を満たすすべての言語 $L \subseteq \Sigma^*$ からなる。すなわち、すべてのファンアウトが高々 f である、ある簡約された二分・線形・非消去の作業形 MCFG G によって $L = L(G)$ と表され、かつ L が (f, h) -タプル代入可能である。

注意 3.16 (対象クラスの意味論的性質). 言語 L がクラス $\mathcal{C}_{f,h}^{\text{mcf}}$ に属するためには、次の二条件が満たされなければならない。

- (i) L が、ファンアウト高々 f の簡約された作業形 MCFG G によって $L = L(G)$ と表示されること。
- (ii) 言語 $L(G)$ が (f, h) -タプル代入可能であること。

条件 (i) は具体的な文法表示に関する条件である。これに対して条件 (ii) は、文法の規則の形ではなく、生成される言語全体の文コンテキスト分布に関する条件である。この意味で、 $\mathcal{C}_{f,h}^{\text{mcf}}$ は意味論的对象クラスである。

本論文では、与えられた作業形 MCFG G から、 $L(G)$ が (f, h) -タプル代入可能であるかどうかを常に決定できるとは主張しない。ただし、代入可能性が失敗することは半決定可能である。実際、失敗は有限個の語と文コンテキストによって証明できる。

具体的には、ある $1 \leq d \leq f$ 、タプル

$$\vec{x}, \vec{y} \in (\Sigma^*)^d$$

およびアリティ d の文コンテキスト E, F が存在して、

$$\begin{aligned} h^{(d)}(\vec{x}) &= h^{(d)}(\vec{y}), \\ E[\vec{x}] &\in L(G), & E[\vec{y}] &\in L(G), \\ F[\vec{x}] &\in L(G), & F[\vec{y}] &\notin L(G) \end{aligned}$$

となれば、 (f, h) -タプル代入可能性は失敗している。

ここで、コンテキスト E は、 $\vec{x}$ と $\vec{y}$ が少なくとも一つの受理文コンテキストを共有することを示す。一方、コンテキスト F は、

$$F \in \mathcal{D}_{L(G)}^{(d)}(\vec{x}) \setminus \mathcal{D}_{L(G)}^{(d)}(\vec{y})$$

であることを示す。したがって、

$$\mathcal{D}_{L(G)}^{(d)}(\vec{x}) \neq \mathcal{D}_{L(G)}^{(d)}(\vec{y}),$$

となり、定義 3.14 の条件に反する。

有限のタプルと文コンテキストは、長さの短いものから順に実効的に列挙できる。また、 $MCFG$ の所属問題は決定可能なので、各候補について上の所属・非所属条件を有限時間で検査できる。したがって、失敗証拠が存在する場合には、探索によっていつかそれを発見できる。ただし、失敗証拠が存在しない場合に探索が停止するとは限らないため、これは決定手続ではなく半決定手続である。

この意味論的な非実効性は、本論文の極限同定定理には支障を与えない。学習器には、対象文法 G も、対象が (f, h) -タプル代入可能であるという証明も入力されない。定理が主張するのは、未知の対象言語が実際に $\mathcal{C}_{f,h}^{mc}$ に属しているならば、その対象に応じた有限特徴標本が存在し、その特徴標本を含む十分な正例データを受け取った後には、固定された学習器の仮説言語が対象言語と一致する、ということである。

対象言語が (f, h) -タプル代入可能でない場合には、本論文の厳密再構成定理および極限同定定理は適用できない。したがって、学習器が有限正例標本 K から構成する仮説言語

$$L(\hat{G}_0(K))$$

が、未知の対象言語と一致するとは保証されない。

ただし、学習器自体は、意味論的仮定が成り立つかどうかにかかわらず、任意の有限正例標本 K に対して定義されている。さらに、構成された仮説文法 $\hat{G}_0(K)$ は、標本中のすべての語を生成する。したがって、

$$K \subseteq L(\hat{G}_0(K))$$

が常に成り立つ。

つまり、学習器が観測済みの正例を仮説言語から取りこぼすことはない。問題になりうるのは、標本 K にまだ現れていない語である。具体的には、

$$L(\hat{G}_0(K)) \setminus K$$

に属する語の中に、実際の対象言語には属さない語が含まれる可能性がある。

したがって、 (f, h) -タプル代入可能性が保証するのは、観測済みの正例を再現できることではなく、有限標本から未観測の語へ仮説を拡張するときに、余分な語を生成しないという健全性である。

4 例

抽象的な再構成証明に入る前に、よく知られたブロック同期言語において、固定観測準同型が何を捉えるためのものかを示す具体的文法を記す。固定された正則包絡が与えるのは粗いゾーンパターンだけであり、等式制約は正例から分布的に回復される。また、これらの例について意味論的仮定も検証し、実際に対応する固定観測ファイバーに属することを示す。MCFL における文字数による分離と較正については [14] を参照されたい。

有限順序アルファベット $\Sigma_m = \{a_1, \dots, a_m\}$ に対して、

$$R_m = a_1^* a_2^* \cdots a_m^*$$

とおく。 D_m を、状態集合 $1, \dots, m, \perp$ 、初期状態 1、受理状態 $1, \dots, m$ をもち、遷移が

$$i \cdot a_j = \begin{cases} j, & i \leq j, \\ \perp, & i > j, \end{cases} \quad \perp \cdot a_j = \perp$$

で与えられる、 R_m の標準決定性オートマトンとする。その遷移準同型を $h_m : \Sigma_m^* \rightarrow M_m$ とする。

補題 4.1 (ゾーン準同型). 任意の語 $u, v \in \Sigma_m^*$ に対し、 $h_m(u) = h_m(v)$ ならば、 $u \in R_m$ と $v \in R_m$ は同値である。さらに、 $m \geq 2$ かつ $u \in \{a_1^n \cdots a_m^n \mid n \geq 1\}$ ならば、 $h_m(u) \neq h_m(\varepsilon)$ である。

証明. 遷移値 $h_m(w)$ は初期状態の像を決定するので、正則言語 R_m への所属も決定する。 $m \geq 2$ かつ $u = a_1^n \cdots a_m^n$ ($n \geq 1$) ならば、 u が誘導する遷移は初期状態 1 を m へ送る。一方、空語が誘導するのは恒等遷移であり、1 を 1 へ送る。したがって両者の遷移値は異なる。□

命題 4.2 (等長ブロックは固定ゾーン代入可能である). 任意の $m \geq 2$ に対して、言語

$$E_m^+ = \{a_1^n \cdots a_m^n \mid n \geq 1\}$$

は、任意のアリティ $r \geq 1$ について (r, h_m) -タプル代入可能である。

証明. アリティ $d \geq 1$ を固定する。 $\vec{x}, \vec{y} \in (\Sigma_m^*)^d$ が成分ごとに同じ h_m -型をもち、次のような受理文コンテキスト E を共有すると仮定する。

$$E[\vec{x}] = a_1^n \cdots a_m^n, \quad E[\vec{y}] = a_1^{n'} \cdots a_m^{n'}$$

ここで $n, n' \geq 1$ である。各 $1 \leq j \leq m$ について、外側コンテキスト E 自身が供給する文字 a_j の個数を k_j とおく。 E はどちらの場合にも同じコンテキストなので、 k_j は $\vec{x}$ と $\vec{y}$ のどちらを代入しても変わらない。

一方、

$$E[\vec{x}] = a_1^n \cdots a_m^n$$

であるから、完成した語に含まれる a_j の個数を数えると

$$k_j + \sum_{i=1}^d |x_i|_{a_j} = n$$

を得る。同様に、

$$E[\vec{y}] = a_1^{n'} \cdots a_m^{n'}$$

であるから

$$k_j + \sum_{i=1}^d |y_i|_{a_j} = n'$$

である。後者から前者を引けば、外側コンテキストの寄与 k_j が打ち消されて、

$$\sum_{i=1}^d |y_i|_{a_j} - \sum_{i=1}^d |x_i|_{a_j} = n' - n \quad (1 \leq j \leq m) \quad (1)$$

を得る。次に F を $\vec{x}$ の任意の受理コンテキストとし、 $F[\vec{x}] = a_1^N \cdots a_m^N$ ($N \geq 1$) とする。各成分について

$$h_m(x_i) = h_m(y_i) \quad (1 \leq i \leq d)$$

が成り立つ。

コンテキスト F による充填では、 F がもともと含んでいる終端記号部分は固定されており、 $\vec{x}$ と $\vec{y}$ の各成分は、それぞれ同じ位置に代入される。さらに h_m はモノイド準同型なので、連結された語の h_m -値は、各部分の h_m -値の積として計算できる。したがって、各成分の h_m -値が一致することから

$$h_m(F[\vec{x}]) = h_m(F[\vec{y}])$$

を得る。

仮定より $F[\vec{x}] \in R_m$ である。また、補題 4.1 により、 R_m への所属は h_m -値だけで決まる。したがって、 $F[\vec{x}]$ と同じ h_m -値をもつ $F[\vec{y}]$ も R_m に属する。すなわち、

$$F[\vec{y}] \in R_m.$$

式 (1) により、 $F[\vec{y}]$ におけるすべての文字数は $N + (n' - n)$ に等しい。この共通値は 0 にはなりえない。もし 0 なら $F[\vec{y}] = \varepsilon$ であり、 $h_m(F[\vec{x}]) = h_m(F[\vec{y}]) = h_m(\varepsilon)$ となって、補題 4.1 に矛盾する。したがって $F[\vec{y}] \in E_m^+$ である。逆向きも対称的に従うため、二つのタプル分布は等しい。□

定義 4.3 (固定順序ブロック包絡). $k \geq 1$ とする。互いに異なる文字

$$A = \{a_1, \dots, a_k\}$$

と、 A と交わらない有限アルファベット Δ をとる。さらに、固定された区切り語

$$s_0, s_1, \dots, s_k \in \Delta^*$$

をとり、

$$\Sigma = A \uplus \Delta$$

とおく。

このとき、

$$R = s_0 a_1^+ s_1 a_2^+ s_2 \cdots s_{k-1} a_k^+ s_k \subseteq \Sigma^*$$

を、固定順序ブロック包絡と呼ぶ。

各 $w \in R$ は一意に

$$w = s_0 a_1^{n_1} s_1 a_2^{n_2} s_2 \cdots s_{k-1} a_k^{n_k} s_k, \quad n_1, \dots, n_k \geq 1,$$

と表される。そのブロック長ベクトルを

$$\ell_R(w) := (n_1, \dots, n_k) \in \mathbb{N}_{>0}^k$$

と定め、 j 番目の成分を $\ell_j(w) := n_j$ と書く。

補題 4.4 (固定順序ブロック包絡における長さ等式の保存). $R \subseteq \Sigma^*$ を、定義 4.3 の固定順序ブロック包絡とする。また、 $\mathcal{A}_R$ を R を認識する完全 DFA とし、

$$h_R : \Sigma^* \longrightarrow M_R$$

をその遷移モノイドへの準同型とする。

ブロック添字の有限集合

$$\Lambda \subseteq \{1, \dots, k\}^2$$

に対して、

$$L_\Lambda := \{w \in R \mid \forall (p, q) \in \Lambda, \ell_p(w) = \ell_q(w)\}$$

と定める。

このとき、任意の $f \geq 1$ に対して、 L_Λ は (f, h_R) -タプル代入可能である。

証明. 任意の $1 \leq d \leq f$ を固定する。タプル

$$\vec{x} = (x_1, \dots, x_d), \quad \vec{y} = (y_1, \dots, y_d) \in (\Sigma^*)^d$$

が

$$h_R(x_i) = h_R(y_i) \quad (1 \leq i \leq d) \quad (3)$$

を満たすと仮定する。

さらに、 $\vec{x}$ と $\vec{y}$ が L_Λ に関する文コンテキストを一つ共有するとする。すなわち、あるアリティ d の文コンテキスト E が存在して、

$$E[\vec{x}] \in L_\Lambda, \quad E[\vec{y}] \in L_\Lambda \quad (4)$$

であると仮定する。

各 $1 \leq j \leq k$ とタプル $\vec{z} = (z_1, \dots, z_d)$ に対して、

$$N_j(\vec{z}) := \sum_{i=1}^d |z_i|_{a_j}$$

とおく。これは、タプル $\vec{z}$ の全成分が供給する文字 a_j の総数である。

また、文コンテキスト E の穴以外の固定部分に含まれる文字 a_j の個数を $C_j(E)$ と書く。すると、任意の $\vec{z}$ に対して

$$|E[\vec{z}]|_{a_j} = C_j(E) + N_j(\vec{z}) \quad (5)$$

である。

ここで $(p, q) \in \Lambda$ を任意にとる。仮定 (4) より、 $E[\vec{x}]$ と $E[\vec{y}]$ はともに L_Λ に属するので、

$$C_p(E) + N_p(\vec{x}) = C_q(E) + N_q(\vec{x})$$

および

$$C_p(E) + N_p(\vec{y}) = C_q(E) + N_q(\vec{y})$$

が成り立つ。後者から前者を引くと、

$$N_p(\vec{y}) - N_p(\vec{x}) = N_q(\vec{y}) - N_q(\vec{x}) \quad ((p, q) \in \Lambda) \quad (6)$$

を得る。

次に、

$$F \in \mathcal{D}_{L_\Lambda}^{(d)}(\vec{x})$$

を任意にとる。すなわち、

$$F[\vec{x}] \in L_\Lambda \quad (7)$$

である。

条件 (3) と h_R の準同型性から、文コンテキスト F の固定部分を変えずに各 x_i を y_i に置き換えても、語全体の h_R -値は変化しない。したがって、

$$h_R(F[\vec{x}]) = h_R(F[\vec{y}]). \quad (8)$$

$F[\vec{x}] \in L_\Lambda \subseteq R$ であり、 h_R は R を認識する DFA の遷移準同型なので、(8) から

$$F[\vec{y}] \in R \quad (9)$$

が従う。

文コンテキスト F の固定部分に含まれる文字 a_j の個数を $C_j(F)$ と書く。任意の $(p, q) \in \Lambda$ に対して、(7) より

$$C_p(F) + N_p(\vec{x}) = C_q(F) + N_q(\vec{x}). \quad (10)$$

一方、(6) より

$$N_p(\vec{y}) - N_p(\vec{x}) = N_q(\vec{y}) - N_q(\vec{x}).$$

これと (10) を合わせると、

$$\begin{aligned} C_p(F) + N_p(\vec{y}) &= C_p(F) + N_p(\vec{x}) + (N_p(\vec{y}) - N_p(\vec{x})) \\ &= C_q(F) + N_q(\vec{x}) + (N_q(\vec{y}) - N_q(\vec{x})) \\ &= C_q(F) + N_q(\vec{y}). \end{aligned}$$

したがって、

$$\ell_p(F[\vec{y}]) = \ell_q(F[\vec{y}]) \quad ((p, q) \in \Lambda).$$

これと (9) から

$$F[\vec{y}] \in L_\Lambda$$

を得る。よって

$$\mathcal{D}_{L_\Lambda}^{(d)}(\vec{x}) \subseteq \mathcal{D}_{L_\Lambda}^{(d)}(\vec{y}).$$

$\vec{x}$ と $\vec{y}$ を交換した同じ議論により、逆の包含も成り立つ。したがって、

$$\mathcal{D}_{L_\Lambda}^{(d)}(\vec{x}) = \mathcal{D}_{L_\Lambda}^{(d)}(\vec{y}).$$

$d \leq f$ は任意であったから、 L_Λ は (f, h_R) -タプル代入可能である。 $\square$

例 4.5 (三ブロック一致言語).

$$L_3 = \{a^n b^n c^n \mid n \geq 1\}, \quad R_3 = a^* b^* c^*$$

とする。 h_{R_3} を、 R_3 を認識する標準 DFA の遷移準同型とする。この準同型は、各成分が属する粗いブロックゾーンを記録するが、三つのブロック長が等しいことは記録しない。

命題 4.6 (L_3 の作業形表示). 言語 L_3 は、ファンアウト 2 の簡約された二分・線形・非消去の作業形 MCFG 表示をもつ。

証明. $V = \{S, T, A, A_a, A_b, A_c\}$ とし、 $\mu(A) = 2$ 、その他のすべての非終端記号のファンアウトを 1 とする。次の規則を用いる。

$$\begin{aligned} S &\rightarrow T, & A_a &\rightarrow (a), & A_b &\rightarrow (b), & A_c &\rightarrow (c), \\ A &\rightarrow (x^1, y^1)(A_a, A_b), & A &\rightarrow (ax^1, bx^2y^1)(A, A_c), \\ T &\rightarrow (x^1x^2y^1)(A, A_c). \end{aligned}$$

直接の帰納法により、 $L_A = \{(a^n, b^n c^{n-1}) \mid n \geq 1\}$ であり、最上位規則はちょうど $a^n b^n c^n$ を生成する。この文法は定義 3.10 の作業形にある。 $\square$

系 4.7 (三ブロックの例は固定観測クラスに属する). 任意の $f \geq 2$ に対して、 $L_3 \in \mathcal{C}_{f, h_{R_3}}^{\text{mcf}}$ である。

証明. 表示は命題 4.6 で与えられる。意味論的仮定は、命題 4.2 において $(a_1, a_2, a_3) = (a, b, c)$ とおけば従う。 $\square$

例 4.8 (四ブロック並列一致言語).

$$L_{\parallel} = \{a^n \# b^n \# c^n \# d^n \mid n \geq 1\}, \quad P = a^+ \# b^+ \# c^+ \# d^+$$

とする。 h_P を、 P を認識する標準 DFA の遷移準同型とする。ここでも有限観測が与えるのは正則包絡であり、ブロック長の等しさは正例から回復される分布的情報である。

命題 4.9 ($L_{\parallel}$ の作業形表示). 言語 $L_{\parallel}$ は、ファンアウト 2 の簡約された二分・線形・非消去の作業形 MCFG 表示をもつ。

証明. H が $\#$ を導出し、 A_a, A_b, A_d がそれぞれ $(a), (b), (d)$ を導出するものとし、 A のファンア

ウトを 2 とする。次を用いる。

$$A \rightarrow (x^1 \# y^1, c \# d)(A_a, A_b)$$

および

$$A \rightarrow (ax^1b, cx^2y^1)(A, A_d).$$

すると A は $n \geq 1$ に対する $(a^n \# b^n, c^n \# d^n)$ だけを導出する。最上位規則

$$T \rightarrow (x^1y^1x^2)(A, H)$$

と $S \rightarrow T$ を合わせれば、ちょうど $L_{\parallel}$ が得られる。 $\square$

系 4.10 (並列一致の例は固定観測クラスに属する). 任意の $f \geq 2$ に対して、 $L_{\parallel} \in \mathcal{C}_{f, h_P}^{\text{mcf}}$ である。

証明. 表示は命題 4.9 で与えられる。

$$P = a^+ \# b^+ \# c^+ \# d^+$$

を、可視ブロック文字

$$(a_1, a_2, a_3, a_4) = (a, b, c, d),$$

区切りアルファベット $\Delta = \{\#\}$ 、および区切り語

$$(s_0, s_1, s_2, s_3, s_4) = (\varepsilon, \#, \#, \#, \varepsilon)$$

をもつ固定順序ブロック包絡とみなす。意味論的仮定は、補題 4.4 において

$$\Lambda = \{(1, 2), (2, 3), (3, 4)\}$$

とおけば従う。 $\square$

例 4.11 (交差直列二本スパイン言語).

$$L_{\times} = \{a^n b^m c^n d^m \mid n, m \geq 1\}, \quad Q = a^+ b^+ c^+ d^+$$

とする。 h_Q を、 Q を認識する標準 DFA の遷移準同型とする。この例には、独立な二本の一致スパインがある。

命題 4.12 ($L_{\times}$ の作業形表示). 言語 $L_{\times}$ は、ファンアウト 2 の簡約された二分・線形・非消去の作業形 MCFG 表示をもつ。

証明. ファンアウト 2 の二つの非終端記号 A, B を用いる。終端非終端記号 A_a, A_b, A_c, A_d は、それぞれ $(a), (b), (c), (d)$ を導出するものとする。非終端記号 A は、

$$A \rightarrow (x^1, y^1)(A_a, A_c), \quad A \rightarrow (ax^1, x^2y^1)(A, A_c)$$

によって (a^n, c^n) を導出し、 B は

$$B \rightarrow (x^1, y^1)(A_b, A_d), \quad B \rightarrow (bx^1, x^2y^1)(B, A_d)$$

によって (b^m, d^m) を導出する。最上位規則

$$T \rightarrow (x^1y^1x^2y^2)(A, B)$$

と $S \rightarrow T$ によって、ちょうど $L_{\times}$ が生成される。 $\square$

系 4.13 (交差直列の例は固定観測クラスに属する). 任意の $f \geq 2$ に対して、 $L_{\times} \in \mathcal{C}_{f, h_Q}^{\text{mcf}}$ である。

証明. 表示は命題 4.12 で与えられる。

$$Q = a^+ b^+ c^+ d^+$$

を、可視ブロック文字

$$(a_1, a_2, a_3, a_4) = (a, b, c, d),$$

空の区切りアルファベット、および

$$s_0 = s_1 = s_2 = s_3 = s_4 = \varepsilon$$

をもつ固定順序ブロック包絡とみなす。意味論的仮定は、補題 4.4 において

$$\Lambda = \{(1, 3), (2, 4)\}$$

とおけば従う。 □

5 正準学習器

学習器が用いるのは、固定されたパラメータ f と h 、および現在の有限な正例標本だけである。対象の証人表示は、有限特徴標本が存在することを示す証明の中でのみ用いる。以下の精密化が保存するのは成分ごとの出力 h -型だけであり、再構成に必要な具体的露出文脈は特徴標本によって与えられる。

5.1 出力型精密化

再構成の証明では、証人文法の有限精密化を用いる。この精密化が記録するのは、導出された各タプルの出力 h -型だけである。周囲の文の中へタプル成分が配置される順序や、境界区間の h -値は記録しない。これらの情報は、有限特徴標本に含まれる具体的な証人付き分割と露出文脈から復元する。学習器の単位規則が、実際に共有された標本文脈によって保護されるため、これで十分である。

定義 5.1 (テンプレート評価). $\mu(B) = d_B$ 、 $\mu(C) = d_C$ である二分規則

$$\rho: A \rightarrow (\alpha_1, \dots, \alpha_e)(B, C)$$

をとる。ここで $e = \mu(A)$ であり、各 α_ℓ は

$$\Gamma_\rho := \Sigma \uplus \{x^1, \dots, x^{d_B}\} \uplus \{y^1, \dots, y^{d_C}\}$$

上の語、すなわち

$$\alpha_\ell \in \Gamma_\rho^* \quad (1 \leq \ell \leq e)$$

である。この Γ_ρ^* の元を、規則 ρ のテンプレート語と呼ぶ。

$\mathbf{q} = (q_1, \dots, q_{d_B}) \in M^{d_B}$ および $\mathbf{r} = (r_1, \dots, r_{d_C}) \in M^{d_C}$ に対して、写像

$$\eta_{\mathbf{q}, \mathbf{r}}: \Gamma_\rho \rightarrow M$$

を

$$\begin{aligned} \eta_{\mathbf{q}, \mathbf{r}}(a) &:= h(a) & (a \in \Sigma), \\ \eta_{\mathbf{q}, \mathbf{r}}(x^i) &:= q_i & (1 \leq i \leq d_B), \\ \eta_{\mathbf{q}, \mathbf{r}}(y^j) &:= r_j & (1 \leq j \leq d_C) \end{aligned}$$

によって定める。

この写像を語へ一意に準同型拡張して得られるモノイド準同型を

$$\hat{\eta}_{\mathbf{q}, \mathbf{r}}: \Gamma_\rho^* \rightarrow M$$

とする。すなわち、

$$\hat{\eta}_{\mathbf{q}, \mathbf{r}}(\varepsilon) = 1_M$$

であり、テンプレート語

$$\beta = z_1 \cdots z_t \quad (z_1, \dots, z_t \in \Gamma_\rho)$$

に対して

$$\hat{\eta}_{\mathbf{q},\mathbf{r}}(\beta) = \eta_{\mathbf{q},\mathbf{r}}(z_1) \cdots \eta_{\mathbf{q},\mathbf{r}}(z_t)$$

である。

規則 ρ におけるテンプレート語 β の評価を

$$\text{ev}_\rho(\beta; \mathbf{q}, \mathbf{r}) := \hat{\eta}_{\mathbf{q},\mathbf{r}}(\beta) \in M$$

と定義する。さらに、

$$\text{out}_\rho(\mathbf{q}, \mathbf{r}) := (\text{ev}_\rho(\alpha_1; \mathbf{q}, \mathbf{r}), \dots, \text{ev}_\rho(\alpha_e; \mathbf{q}, \mathbf{r})) \in M^e$$

と定義する。

定義 5.2 (出力型精密化). G と h が与えられたとき、完全出力型精密化 G^h は、新しい開始記号 $\tilde{S}$ と、 $A \in V \setminus \{S\}$ 、 $\mathbf{p} \in M^{\mu(A)}$ に対する非終端記号 $A_{\mathbf{p}}$ をもつ。その規則は次のように定める。各開始規則 $S \rightarrow A$ と各 $p \in M$ に対し、 $\tilde{S} \rightarrow A_{(p)}$ を加える。各終端規則 $A \rightarrow (a)$ に対し、 $A_{(h(a))} \rightarrow (a)$ を加える。各二分規則 $\rho: A \rightarrow (\alpha_1, \dots, \alpha_e)(B, C)$ と、すべての $\mathbf{q} \in M^{\mu(B)}$ 、 $\mathbf{r} \in M^{\mu(C)}$ に対し、 $A_{\text{out}_\rho(\mathbf{q}, \mathbf{r})} \rightarrow \rho(B_{\mathbf{q}}, C_{\mathbf{r}})$ を加える。トリムされた出力型精密化 $\tilde{G}_0$ とは、 $\tilde{S}$ からのある成功導出に現れる型付き非終端記号と型付き規則だけを残して得られる部分文法である。

命題 5.3 (出力型不変量). G^h の任意の非終端記号 $A_{\mathbf{p}}$ について、次が成り立つ。

- (i) G^h において $A_{\mathbf{p}} \Rightarrow^* \vec{u}$ ならば、 $h^{\mu(A)}(\vec{u}) = \mathbf{p}$ であり、型添字を消去すると A からの正しい G -導出が得られる。
- (ii) 根が開始記号でない非終端記号である任意の G -導出木は、各節点に、その節点で導出されるタプルの成分ごとの h -型を付すことによって、一意に G^h -導出木へ持ち上がる。
- (iii) $L(G^h) = L(G)$ であり、 $\tilde{G}_0$ へのトリミングは文字列言語を保存する。

証明. (i) は導出に関する帰納法による。終端規則の場合は直ちに従う。二分規則の場合、帰納法の仮定から子の出力型 $\mathbf{q}$ と $\mathbf{r}$ が得られ、親の出力型は h の準同型性により、ちょうど $\text{out}_\rho(\mathbf{q}, \mathbf{r})$ である。添字を消去すれば、基礎となる G の規則が得られる。(ii) では、各節点に、その節点で導出されるタプルの h -型を付す。すると定義 5.2 により、各内部節点に必要な型付き規則がちょうど存在する。(iii) の二つの包含は (i) と (ii) から従い、トリミングで除かれるのは、いかなる成功導出にも現れない対象だけである。□

$\tilde{G}_0$ に残る型付き非終端記号 $X = A_{\mathbf{p}}$ に対し、そのタプル言語を L_X と書く。タプルおよび具体的な文コンテキストの上に、長さ辞書式順序を精密化する全有効順序を一つ固定する。 L_X における最小のタプルを $\omega(X)$ とする。

補題 5.4 (具体的な露出文脈). $\tilde{G}_0$ に残る任意の型付き非終端記号 $X = A_{\mathbf{p}}$ に対し、すべての $\vec{u} \in L_X$ について $E_X[\vec{u}] \in L(G)$ を満たす、具体的なアリティ $\mu(A)$ の文コンテキスト E_X が存在する。 X が型付き開始規則 $\tilde{S} \rightarrow X$ の子として現れるなら、単項文脈 $\square_1$ を選ぶことができる。

証明. X はトリミング後にも残っているので、 $\tilde{G}_0$ のある成功導出木のある節点に現れる。すべての型添字を消去し、同じ節点を、成功した G -導出中の A の出現とみなす。その導出の残りの部分は、この出現で導出されたタプルを囲む具体的な文コンテキスト E_X を定める。 $\vec{u} \in L_X$ なら、その節点に A から $\vec{u}$ への導出を代入しても、基礎文法 G には依然として正しい成功導出が存在す

る。したがって $E_X[\vec{u}] \in L(G)$ である。 X が開始記号から直接到達される場合、外側の文脈は $\square_1$ である。 $\square$

定義 5.5 (露出文脈). 残っている各 X について、 X が現れる $\tilde{G}_0$ の成功導出を一つ選ぶ。その出現を根とする部分木を削除し、露出したタプルの名前付き穴を残して得られる具体的な文コンテキストを $\chi(X)$ とする。補題 5.4 により、この文脈はすべての $\vec{u} \in L_X$ について $\chi(X)[\vec{u}] \in L(G)$ を満たす。開始規則の子 X に対しては、慣例として $\chi(X) = \square_1$ を選ぶ。

5.2 特徴標本

定義 5.6 (証人精密化の表示相対的特徴標本). $\tilde{G}_0$ をトリムされた出力型精密化とする。残っている各型付き非終端記号 X に対し、語 $\chi(X)[\omega(X)]$ を含める。 $\tilde{G}_0$ の各終端規則 $X \rightarrow (a)$ に対し、 $\chi(X)[(a)]$ を含める。各二分規則 $R: X \rightarrow \rho(Y, Z)$ に対し、 $\chi(X)[\rho(\omega(Y), \omega(Z))]$ を含める。これら有限個の語の和集合を $\text{CS}(\tilde{G}_0)$ と書く。

表示相対的標本 $\text{CS}(\tilde{G}_0)$ は、選ばれた証人表示 G と、そのトリムされた出力型精密化に相対的である。学習器には、この表示も標本も与えられない。 $\text{CS}(\tilde{G}_0)$ の役割は、Gold の同定の意味で有限十分な正例集合が存在することを証明することだけである。

補題 5.7 (特徴標本の正例性と有限性). $\text{CS}(\tilde{G}_0)$ は $L(G)$ の有限部分集合である。

証明. 残っている型付き非終端記号と型付き規則は有限個である。定義 5.5 により、 $\chi(X)$ は L_X のすべてのタプルを受理する。アンカー $\omega(X)$ 、終端規則 $X \rightarrow (a)$ に対する終端タプル (a) 、および二分規則 $X \rightarrow \rho(Y, Z)$ に対するタプル $\rho(\omega(Y), \omega(Z))$ は、いずれも L_X に属する。したがって、上で挙げた各語は $L(G)$ に属する。 $\square$

命題 5.8 (具体的文脈の十分性). G を証人となる作業形表示とし、 $\tilde{G}_0$ をそのトリムされた出力型精密化とする。残っている各型付き非終端記号 X について、アンカータプル $\omega(X)$ と、 X から導出されるすべてのタプルを受理する具体的露出文脈 $\chi(X)$ を選ぶ。このとき、次のデータは、正準学習器が $\tilde{G}_0$ のすべての規則をシミュレートするために十分である。

- (i) 残っている各型付き記号の成分ごとの出力 h -型、
- (ii) 残っている各型付き記号について一つの露出されたアンカー、
- (iii) 残っている各型付き規則について一つの露出された充填例。

学習器の非終端記号に、これ以外の文レベルのインターフェース標識を付す必要はない。

証明. 出力型により、型付き親アンカーと対応する充填済み規則タプルは、成分ごとに同じ h -値をもつ。それらを露出する二つの標本語は同じ具体的文脈 $\chi(X)$ を用いるため、学習器は両観測タプル値を保護された単位規則で結ぶことができる。充填済み二分規則語は、親タプル内にある二つの子アンカーの実際の変数区間を記録する。アンカー自体は、それぞれ自身の露出語を通じて観測されていてよい。こうして得られる二分証人は、基礎となる線形テンプレートを再構成する。終端規則と開始規則は、対応する露出された終端語とアンカー語によって処理される。規則ごとの形式的

シミュレーションは補題 6.6 で与える。

□

5.3 観測タプルと具体的証人

定義 5.9 (標本語中のタプル出現). $w \in K$ におけるアリティ d のタプル出現とは、 E が具体的なアリティ d の文コンテキスト、 $\vec{x} \in (\Sigma^*)^d$ 、かつ $E[\vec{x}] = w$ であるような対 $(E, \vec{x})$ をいう。同値な言い方をすれば、 w の中で名前付きスロットを d 個選ぶ。正の長さをもつスロットは区間であり、空スロットは切断位置である。同じ切断位置を複数の空スロットが共有する場合には、同一切断位置にある局所順序を付す。

例 5.10 (空スロットと局所順序). $w = ab$ とし、タプル $\vec{x} = (a, \varepsilon, b)$ を考える。文脈 $E = \square_1 \square_2 \square_3$ は $E[\vec{x}] = ab$ を満たす。これは w の中の出現として、 $\square_1$ に対する区間 $[0, 1]$ 、 $\square_2$ に対する長さゼロの区間 $[1, 1]$ 、および $\square_3$ に対する区間 $[1, 2]$ によって表される。二つの空スロットが同じ切断位置に現れる場合、同一切断位置にある局所順序によって両者を区別する。たとえば $\vec{y} = (a, \varepsilon, \varepsilon, b)$ に対して、 $\square_1 \square_2 \square_3 \square_4$ と $\square_1 \square_3 \square_2 \square_4$ は、どちらも埋めると同じ語 ab になるが、異なる具体的出現である。 a と b の間の切断位置における局所順序は、 $\square_2 < \square_3$ か $\square_3 < \square_2$ かを記録する。これは単なる簿記上の仕組みにすぎないが、空成分が存在する場合でも、二分証人から一意な線形テンプレートを再構成できるようにする。

定義 5.11 (観測タプル). $1 \leq d \leq f$ であるタプル $\vec{x} \in (\Sigma^*)^d$ が K のある語中でタプル出現 $(E, \vec{x})$ をもつとき、 $\vec{x}$ は K において観測されるという。学習器は、観測された各タプル $\vec{x}$ に対し非終端記号 $[\vec{x}]$ を一つ用い、さらに新しい開始記号 $\hat{S}$ を用いる。

定義 5.12 (二分証人). 有限標本 K における二分証人は、次のデータからなる。

- (i) K のある語中の親タプル出現 $(E, \vec{z})$ 。ここで $\vec{z} = (z_1, \dots, z_e)$ とする。
- (ii) 二つのタプル値 $\vec{x} = (x_1, \dots, x_{d_B})$ と $\vec{y} = (y_1, \dots, y_{d_C})$ 。各々は K のどこかで観測されているものとする。それらを証明する観測は、親出現と同じ標本語中に現れる必要はない。
- (iii) 各親成分 z_i を、終端記号からなる隙間と、 $\{x^1, \dots, x^{d_B}, y^1, \dots, y^{d_C}\}$ の互いに異なる変数でラベル付けされた変数区間とへ分ける順序付き分割。
- (iv) 各変数は親タプル全体でちょうど一度用いられ、 x^j でラベル付けされた区間の文字列値はちょうど x_j 、 y^k でラベル付けされた区間の文字列値はちょうど y_k である。
- (v) 長さゼロの子成分は、指定された切断位置にある長さゼロの区間として表す。同じ切断位置を複数の長さゼロ区間が用いるとき、それらの局所順序も証人データの一部とする。

各親成分について終端記号からなる隙間と変数ラベルを左から右へ読めば、 $\vec{z} = \rho(\vec{x}, \vec{y})$ を満たす二分・線形・非消去テンプレート ρ が得られる。

注意 5.13 (二分証人の局所性). 親出現が与えるのは、すでに観測された子タプル値が使用される位置である。同じ標本語の中で、子に対する別個の露出文コンテキストまで与える必要はない。完全性証明では、子アンカーはそれぞれ自身の露出文脈を通じて観測され、充填された親規則語が親タプル内の具体的区間を与える。

補題 5.14 (誘導される二分テンプレートの一意性). 親タプル出現と、ラベル付き区間が指定された子成分文字列値をもつ順序付き分割を固定する。長さゼロの区間に対する局所順序も含めれば、この分割は二分・線形・非消去テンプレート ρ を一意に定め、親タプルはちょうど $\rho(\vec{x}, \vec{y})$ である。

証明. 各親成分を左から右へ読む。終端記号からなる隙間は終端文字列として記録し、印を付けた各子区間は対応する変数として記録する。複数の長さゼロの区間が同じ切断位置を共有する場合でも、局所順序によってこの読み取りは全順序になる。各子成分はちょうど一度だけ印を付けられるので、得られる成分テンプレートのタプルでは各変数がちょうど一度現れる。記録された子文字列を代入すると、構成上もとの親成分が再構成されるので、誘導テンプレートは一意である。 $\square$

定義 5.15 (正準学習器). 正準学習器文法 $\hat{G}_0(K)$ は、開始記号 $\hat{S}$ 、アリティが高々 f の観測タプルに対する非終端記号 $[\vec{x}]$ 、および次の規則をもつ。

- (i) 各 $w \in K$ に対し、開始規則 $\hat{S} \rightarrow [(w)]$ を加える。
- (ii) $a \in \Sigma$ である観測された各単項タプル (a) に対し、 $[(a)] \rightarrow (a)$ を加える。
- (iii) 親出現 $(E, \vec{z})$ 、子タプル $\vec{x}, \vec{y}$ 、誘導テンプレート ρ をもつ各二分証人に対し、 $[\vec{z}] \rightarrow \rho([\vec{x}], [\vec{y}])$ を加える。
- (iv) 同じアリティ d をもつ観測タプル $\vec{x}, \vec{y}$ に対し、 $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ であり、かつ $E[\vec{x}] \in K$ と $E[\vec{y}] \in K$ を同時に満たす具体的なアリティ d の文脈 E が存在するとき、単位規則 $[\vec{x}] \rightarrow [\vec{y}]$ を加える。

この文法は単位規則によって拡張されている。単位規則を含まない表示が必要なら、標準的な単位閉包構成によって除去できる。

注意 5.16 (「正準」の意味). ここで「正準」とは、タプル値、出現、分割、出力規則について固定した有効順序に相対して、学習器が決定的かつ集合駆動であることを意味する。返される文法が対象言語の正準最小表示であるという意味ではない。

注意 5.17 (正準学習器の擬似コード). 明確さのため、この構成は次の集合駆動手続きとして記述できる。

- 手順 1. 現在の有限標本 K の中にある、アリティ高々 f のすべてのタプル出現 $(E, \vec{x})$ を列挙し、観測された各タプル値に対して非終端記号 $[\vec{x}]$ を一つ作る。
- 手順 2. すべての $w \in K$ に対して開始規則 $\hat{S} \rightarrow [(w)]$ を加え、観測された各単項文字タプルに対して終端規則 $[(a)] \rightarrow (a)$ を加える。
- 手順 3. 標本語の内部にあるすべての具体的な二分証人を列挙し、対応する二分・線形・非消去規則を加える。
- 手順 4. 同じアリティをもつ観測タプルの各対 $\vec{x}, \vec{y}$ に対し、成分ごとの h -型が等しく、かつ K の一つの共通する具体的な文コンテキストで観測される場合にちょうど、単位規則 $[\vec{x}] \rightarrow [\vec{y}]$ を加える。
- 手順 5. 得られた文法を出力する。必要なら、標準的な単位閉包によって単位規則を除去してから出力してもよい。

すべてのループは、有限標本中で明示的に列挙可能な切断位置と区間の上を走る。したがって、この手続きは有効であり、その固定パラメータ多項式時間上界は定理 7.1 で証明する。

例 5.18 (固定 h 単位規則の小さな実行例). $P = a^+ \# b^+ \# c^+ \# d^+$ とし、その遷移準同型を h_P とする。また

$$K = \{a \# b \# c \# d, aa \# bb \# cc \# dd\}$$

とする。タプル $\vec{x} = (a \# b, c \# d)$ は、第一の標本語に文脈 $E = \square_1 \# \square_2$ とともに現れる。タプル $\vec{y} = (aa \# bb, cc \# dd)$ は、第二の標本語に同じ文脈とともに現れる。 P の標準 DFA において、語 $a \# b$ と $aa \# bb$ は同じ遷移を誘導し、語 $c \# d$ と $cc \# dd$ も同じ遷移を誘導する。したがって $h_P^{(2)}(\vec{x}) = h_P^{(2)}(\vec{y})$ であり、学習器は単位規則 $[\vec{x}] \rightarrow [\vec{y}]$ と $[\vec{y}] \rightarrow [\vec{x}]$ を加える。これは、共有文脈による代入ステップを有限型で保護した版である。 h_P -型の検査がなければ、同様の型なし共有文脈トリガーは、この種の同期例に対して粗すぎる。

学習器に与えられるのは K 、 f 、 h だけである。対象文法、精密化、特徴標本は与えられない。

観察 5.19 (集合駆動性と整合性). 学習器 $K \mapsto \hat{G}_0(K)$ は集合駆動である。さらに、本論文で扱う ε を含まない標本に対して整合的であり、 $K \subseteq L(\hat{G}_0(K))$ が成り立つ。

証明. 集合駆動性は定義 5.15 から直ちに従う。すべての観測タプル、証人、単位規則は、語が提示された順序ではなく、有限集合 K から計算される。整合性について、 $n \geq 1$ である $w = a_1 \cdots a_n \in K$ をとる。学習器は開始規則 $\hat{S} \rightarrow [(w)]$ をもつ。各文字 a_i は観測された単項タプルとして現れるので、終端規則 $[(a_i)] \rightarrow (a_i)$ が存在する。 w の任意の部分文字列の自明でない分割 uv に対し、親タプル (uv) 、子タプル (u) 、 (v) 、およびテンプレート $x^1 y^1$ は二分証人をなす。したがって、部分文字列の長さに関する二分帰納法により $[(w)] \Rightarrow^* (w)$ を得る。ゆえに $w \in L(\hat{G}_0(K))$ であり、これはすべての $w \in K$ について成り立つ。 $\square$

観察 5.20 (正例標本に関する単調性). $K \subseteq K'$ ならば、観測タプル値の明らかな包含を除けば、 $\hat{G}_0(K)$ のすべての非終端記号とすべての規則は $\hat{G}_0(K')$ にも現れる。したがって $L(\hat{G}_0(K)) \subseteq L(\hat{G}_0(K'))$ である。

証明. 定義 5.15 の四種類の規則はすべて、有限標本に存在する正の証拠、すなわち標本語、観測された単項文字タプル、具体的な二分証人、および単位規則のための共有文脈証拠から生成される。 K からより大きな標本 K' へ移ると、そのような証拠は追加されうるが、失われることはない。文法には非終端記号と規則が加わるだけなので、言語の包含が従う。 $\square$

6 健全性と完全再構成

本節では、学習器が意味論的仮定に関して保守的であり、かつ標本が表示相対的特徴標本を含めば完全になることを証明する。

6.1 健全性

定義 6.1 (固定 h 分布同値). $\vec{u}, \vec{x} \in (\Sigma^*)^d$ に対し、 $h^{(d)}(\vec{u}) = h^{(d)}(\vec{x})$ かつ $\mathcal{D}_L^{(d)}(\vec{u}) = \mathcal{D}_L^{(d)}(\vec{x})$ であるとき、 $\vec{u} \equiv_L^d \vec{x}$ と書く。アリティが明らかなき場合は上付き添字を省略する。

補題 6.2 (共有文脈代入可能性). L を (f, h) -タプル代入可能とする。 $d \leq f$ 、 $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ であり、 $E[\vec{x}], E[\vec{y}] \in L$ を満たす具体的なアリティ d の文脈 E が存在するならば、 $\vec{x} \equiv_L^d \vec{y}$ である。

証明. 文脈 E は二つのタプル分布の両方に属する。したがって定義 3.14 により分布は等しく、 h -型の等しさは仮定に含まれている。□

補題 6.3 (充填恒等式). $\rho: \bullet \rightarrow (\alpha_1, \dots, \alpha_e)(\bullet, \bullet)$ を二分・線形・非消去テンプレートとする。 E を親タプルの周囲にあるアリティ e の文コンテキストとし、 $\vec{y}$ を固定する。このとき $E[\rho(\vec{x}, \vec{y})]$ 中の x -変数を穴で置き換えることにより、

$$E_B^{\rho, E, \vec{y}}[\vec{x}] = E[\rho(\vec{x}, \vec{y})]$$

を満たす具体的なアリティ d_B の文脈 $E_B^{\rho, E, \vec{y}}$ が定まる。同様に、文脈 $E_C^{\rho, E, \vec{x}}$ は

$$E_C^{\rho, E, \vec{x}}[\vec{y}] = E[\rho(\vec{x}, \vec{y})]$$

を満たす。

証明. 各子変数はテンプレート中にちょうど一度現れる。兄弟タプルと親文脈を固定すると、選んだ子変数が占めていた位置が、左から右への順序を継承した名前付き穴になる。それらの穴へ子タプルを再び代入すると、もとの充填された文が復元される。□

補題 6.4 (証人付き合成は同値性を保存する). L を (f, h) -タプル代入可能とする。具体的な親文脈 E に対し $E[\rho(\vec{x}, \vec{y})] \in L$ であり、さらに $\vec{u} \equiv_L \vec{x}$ および $\vec{v} \equiv_L \vec{y}$ とする。このとき $\rho(\vec{u}, \vec{v}) \equiv_L \rho(\vec{x}, \vec{y})$ である。

証明. 補題 6.3 により、誘導された B 側文脈は $E_B^{\rho, E, \vec{y}}[\vec{x}] = E[\rho(\vec{x}, \vec{y})] \in L$ を満たす。 $\vec{u} \equiv_L \vec{x}$ なので、この文脈は $\vec{u}$ も受理し、 $E[\rho(\vec{u}, \vec{y})] \in L$ となる。次に、兄弟を $\vec{u}$ に固定した誘導 C 側文脈を用いる。 $\vec{v} \equiv_L \vec{y}$ なので、 $E[\rho(\vec{u}, \vec{v})] \in L$ を得る。二つの親タプルの成分ごとの h -型は等しい。実際、 $h^{(d_B)}(\vec{u}) = h^{(d_B)}(\vec{x})$ 、 $h^{(d_C)}(\vec{v}) = h^{(d_C)}(\vec{y})$ であり、テンプレート評価は準同型的だからである。したがって、同じ具体的な親文脈 E が二つの親タプルをともに受理し、補題 6.2 から結論が従う。□

命題 6.5 (学習器の健全性). L を (f, h) -タプル代入可能とし、 $K \subseteq L$ とする。 $\hat{G}_0(K)$ において $[\vec{x}] \Rightarrow^* \vec{u}$ ならば、 $\vec{u} \equiv_L \vec{x}$ である。したがって $L(\hat{G}_0(K)) \subseteq L$ である。

証明. $[\vec{x}]$ からの導出に関する帰納法による。終端規則の場合は直ちに従う。単位規則 $[\vec{x}] \rightarrow [\vec{y}]$ が加えられるのは、 $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ であり、かつ具体的な文コンテキスト E が $E[\vec{x}], E[\vec{y}] \in K \subseteq L$ を満たす場合に限られる。補題 6.2 により $\vec{x} \equiv_L \vec{y}$ であり、 $[\vec{y}]$ に対する帰納法の仮定からこの場合が従う。二分規則 $[\vec{x}] \rightarrow \rho([\vec{y}], [\vec{z}])$ の場合、証人は K 中の具体的な親出現 $(E, \vec{x})$ を与えるので、 $E[\rho(\vec{y}, \vec{z})] = E[\vec{x}] \in L$ である。子がそれぞれ $\vec{u}, \vec{v}$ を導出するなら、帰納法の仮定から $\vec{u} \equiv_L \vec{y}$ 、 $\vec{v} \equiv_L \vec{z}$ である。補題 6.4 により $\rho(\vec{u}, \vec{v}) \equiv_L \rho(\vec{y}, \vec{z}) = \vec{x}$ を得る。

開始記号について、任意の導出はある $w_0 \in K$ に対する $\hat{S} \rightarrow [(w_0)]$ から始まる。それが w を導

出するなら、 $(w) \equiv_L (w_0)$ である。空の単項文脈 $\square_1$ は (w_0) を受理するので、 (w) も受理する。したがって $w \in L$ である。 $\square$

6.2 完全性と完全再構成

補題 6.6 (型付き規則のシミュレーション). $\text{CS}(\tilde{G}_0) \subseteq K \subseteq L(G)$ と仮定する。残っている各非終端記号 X に対し $\eta(X) := [\omega(X)]$ とおく。このとき、 $\tilde{G}_0$ の各規則は η の下で $\hat{G}_0(K)$ によってシミュレートされる。

- (i) $X \rightarrow (a)$ ならば $\eta(X) \Rightarrow^* (a)$ である。
- (ii) $X \rightarrow \rho(Y, Z)$ ならば $\eta(X) \Rightarrow^* \rho(\eta(Y), \eta(Z))$ である。
- (iii) $\tilde{S} \rightarrow X$ ならば、 $\hat{S} \rightarrow \eta(X)$ は学習器の開始規則である。

証明. (i) について、特徴標本は $\chi(X)[\omega(X)]$ と $\chi(X)[(a)]$ を含む。これら二つの標本語は同じ具体的文コンテキスト $\chi(X)$ を用いる。また、命題 5.3 により $h^{(1)}(\omega(X)) = h(a)$ である。したがって学習器は単位規則 $[\omega(X)] \rightarrow [(a)]$ と終端規則 $[(a)] \rightarrow (a)$ をもつ。

(ii) について、

$$\vec{z}_R := \rho(\omega(Y), \omega(Z))$$

とおく。特徴標本は $\chi(X)[\omega(X)]$ と $\chi(X)[\vec{z}_R]$ の両方を含む。したがって、 $\omega(X)$ と $\vec{z}_R$ は同じ具体的文コンテキスト $\chi(X)$ に現れる。両者は出力型付き言語 L_X に属するため、成分ごとに同じ h -型をもつ。よって定義 5.15 の (iv) により、単位規則

$$[\omega(X)] \rightarrow [\vec{z}_R]$$

が加えられる。

語 $\chi(X)[\vec{z}_R]$ は、二分証人で用いる親出現も与える。 $\vec{z}_R$ の定義により、 $\omega(Y)$ と $\omega(Z)$ の各成分は、 ρ が指定する変数区間に現れ、長さゼロの成分は固定された局所順序規約によって表される。タプル値 $\omega(Y)$ と $\omega(Z)$ は、特徴標本が別々に $\chi(Y)[\omega(Y)]$ と $\chi(Z)[\omega(Z)]$ を含むため、 K において観測される。注意 5.13 により、これらの露出出現は親標本語中にある必要はない。したがって学習器は

$$[\vec{z}_R] \rightarrow \rho([\omega(Y)], [\omega(Z)])$$

を加える。単位規則と二分規則を組み合わせれば、必要なシミュレーションが得られる。

(iii) について、 $\tilde{S} \rightarrow X$ がトリム後に残る開始規則なら、開始規則の子に関する規約により $\chi(X) = \square_1$ である。したがって $\omega(X) \in \text{CS}(\tilde{G}_0) \subseteq K$ であり、 $\hat{S} \rightarrow [(\omega(X))]$ は学習器の開始規則である。 $\square$

命題 6.7 (完全性). $\text{CS}(\tilde{G}_0) \subseteq K \subseteq L(G)$ ならば、 $L(G) \subseteq L(\hat{G}_0(K))$ である。

証明. 導出高に関する帰納法により、残っている各型付き非終端記号 X について、 $\tilde{G}_0$ で X から導出されるすべてのタプルが、学習器文法において $\eta(X) = [\omega(X)]$ から導出されることを示す。終端規則の場合は補題 6.6(i) である。二分規則 $X \rightarrow \rho(Y, Z)$ の場合は、二つの子導出に帰納法の仮定を適用し、その前に補題 6.6(ii) が与える有限シミュレーション区間を置く。これにより、同じ親タプルが $\eta(X)$ から導出される。

命題 5.3 により、成功した任意の G -導出は $\tilde{G}_0$ の成功導出へ持ち上がる。その型付き開始規則は

補題 6.6(iii) によってシミュレートされ、残りの導出木は上で示した帰納法によってシミュレートされる。したがって、 $L(G)$ のすべての語は $\hat{G}_0(K)$ によって生成される。□

定理 6.8 (完全再構成). f と明示的有限準同型 h を固定する。 G をファンアウト高々 f の簡約された作業形二分・線形・非消去 $MCFG$ とし、 $L = L(G)$ が (f, h) -タプル代入可能であるとする。 $\tilde{G}_0$ を G のトリムされた出力型精密化とする。このとき $CS(\tilde{G}_0) \subseteq K \subseteq L$ を満たす任意の有限標本 K に対し、 $L(\hat{G}_0(K)) = L$ が成り立つ。

証明. 健全性は命題 6.5、完全性は命題 6.7 である。□

注意 6.9 (言語レベルでの厳密性). 再構成は言語レベルで厳密である。学習器が、証人表示の非終端記号名や導出木、あるいは対象表示と同型な文法を復元する必要はない。

系 6.10 (極限同定). 固定された f と固定された明示的 h に対し、クラス $\mathcal{C}_{f,h}^{\text{mcf}}$ は正準学習器 $K \mapsto \hat{G}_0(K)$ によって正例から極限同定可能である。 $\mathcal{C}_{f,h}^{\text{mcf}}$ は、任意の $MCFG$ 表示ではなく、簡約された作業形二分・線形・非消去 $MCFG$ 表示の存在によって定義されていることを再確認しておく。

証明. 各対象 $L \in \mathcal{C}_{f,h}^{\text{mcf}}$ に対し、証人文法 G と、その有限特徴標本 $CS(\tilde{G}_0)$ を選ぶ。定理 6.8 に補題 3.6 を適用する。□

注意 6.11 (有界規則ランクへの拡張可能性). 本論文の形式的展開では二分規則という規約を一貫して用いる。同じ具体的証人の方法は、固定された任意の規則ランク上界 r へ拡張できるように見える。すなわち、親タプルを高々 r 個の観測された子タプルの成分へ分割し、健全性証明では子一つずつ置換すればよい。ただし完全な定式化には、対応する r -項証人の定義、列挙上界、シミュレーション補題が必要である。この拡張は今後の課題とし、本論文ではランク r 版の定理を主張しない。

7 仮説構成と露出サイズ

定理 7.1 (固定パラメータ多項式時間構成). 固定された f と固定された明示的な h に対し、文法 $\hat{G}_0(K)$ は、明示的モノイドに依存する定数を除いて、時間 $\|K\|_+^{O(f)}$ で構成可能である。とくに、各固定 f, h に対して、これは出力サイズを含めて $\|K\|_+$ の多項式である。ただし、その多項式の次数は f とともに増大するため、この評価は f に関して一様なものではなく、固定パラメータの意味での評価である。

証明. $n = \|K\|_+$ とおく。固定された $d \leq f$ に対し、長さが高々 n の語におけるアリティ d のタプル出現は、 $O(d)$ 個の切断位置または区間端点と、 d のみに依存する順序データによって決定される。したがって、アリティ d の出現数は $n^{O(d)}$ 個であり、 $d \leq f$ および K の各語について和を取ると、観測タプルは高々 $n^{O(f)}$ 個である。

終端規則と開始規則は直ちに構成できる。単位規則は、同じアリティをもつ観測タプルの対を比較し、成分ごとの h -型の等しさを調べ、さらに観測された具体的出現を列挙して、ある共通の具体的コンテキストが両方のタプルを標本語へ充填するかどうかを判定することで求められる。 M と f

は固定されているため、これらの操作はいずれも $n^{O(f)}$ で抑えられる。

二分証人規則については、親出現、アリティが高々 f の二つの観測済み子タプル値、およびそれらの成分を親成分中に配置する方法と、親成分を終端記号の間隙と高々 $2f$ 個の変数区間へ分割する方法を列挙する。 f は固定されているので、端点、切断位置、局所順序の選び方の総数は $n^{O(f)}$ である。候補となる各分割は、文字列の直接比較によって検査され、その後一つの規則として出力される。したがって、生成される規則の個数と生成に必要な時間は、出力サイズを含めて $n^{O(f)}$ である。

単位規則は学習器文法の一部である。単位規則を含まない作業形文法が必要ならば、多項式サイズの非終端記号集合上で単位閉包を計算し、単位経路を対応する終端規則と二分規則で置き換えればよい。固定された f, h の下では、これは多項式的な増大しか引き起こさない。□

7.1 露出サイズと多項式データの境界

定義 7.2 (露出サイズ). G を対象の証人表示とし、 $\tilde{G}_0$ をそのトリムされた出力型精密化とする。 $B_{\text{exp}}(G, h)$ を、 $\tilde{G}_0$ に残る型付き非終端記号、終端規則、二分規則に対して用いる特徴標本語

$$\chi(X)[\omega(X)], \quad \chi(X)[(a)], \quad \chi(X)[\rho(\omega(Y), \omega(Z))]$$

の正例サイズの最大値として定義する。

命題 7.3 (露出上界の下での特徴標本サイズ). N_{NT} を $\tilde{G}_0$ に残る型付き非終端記号の個数、 N_{rule} を残る開始規則以外の型付き規則の個数とする。このとき

$$|\text{CS}(\tilde{G}_0)| \leq N_{\text{NT}} + N_{\text{rule}}$$

かつ

$$\|\text{CS}(\tilde{G}_0)\|_+ \leq (N_{\text{NT}} + N_{\text{rule}})B_{\text{exp}}(G, h)$$

である。したがって、選ばれた証人表示のサイズに関して N_{NT} 、 N_{rule} 、 $B_{\text{exp}}(G, h)$ が多項式で抑えられる任意の部分クラスは、多項式サイズの特徴標本をもつ。

証明. 定義 5.6 は、残っている各型付き非終端記号について高々一つのアンカー語を、残っている開始規則以外の各型付き規則について高々一つの充填語を加える。重複する語は個数を減らすだけである。各語の正例サイズは高々 $B_{\text{exp}}(G, h)$ なので、二つの上界が得られる。□

完全出力型精密化がもつ型付き非終端記号の個数は高々

$$\sum_{A \in V \setminus \{S\}} |M|^{\mu(A)}$$

であり、二分規則 $A \rightarrow \rho(B, C)$ は高々 $|M|^{\mu(B) + \mu(C)}$ 個の型付き規則を生じる。したがって、固定された f と固定された h に対し、精密化の組合せのサイズは証人文法サイズの定数倍で抑えられる。対象クラス全体で制御されない量は、露出導出の長さ、したがって露出上界である。

この命題は、クラス $\mathcal{C}_{f,h}^{\text{mcf}}$ 全体に対する多項式露出上界を証明するものではない。本論文の無条件の結果は、有限特徴標本による厳密再構成と、与えられた有限標本からの仮説の多項式時間構成である。多項式時間・多項式データ定理が得られるのは、追加の多項式露出上界をもつ部分クラスに限られる。

8 固定観測パラメータ

系 6.10 において、固定準同型 h は学習問題の一部であり、学習器に正例データから適切な有限合同を発見することは要求しない。本節では、この仮定が単なる表示上の便宜ではないことを示す。モノイドサイズに固定上界がある場合は一つの直積観測へまとめられるが、すべての有限観測にわたる非有界和集合は、ファンアウトーの場合ですでに同定不可能である。

定義 8.1 (助言なし和集合クラス). 固定アルファベットと固定ファンアウト上界 f に対し、

$$\mathcal{C}_{f,\bullet}^{\text{mcf}} := \bigcup_h \mathcal{C}_{f,h}^{\text{mcf}}$$

と定義する。ここで和集合は、すべての明示的有限モノイド準同型 $h: \Sigma^* \rightarrow M$ にわたって取る。このクラスの学習器は正例データだけを受け取り、どの準同型が対象の所属を証言するかは与えられない。

補題 8.2 (増大鎖による障害). 言語クラス $\mathcal{C}$ が

$$L_1 \subsetneq L_2 \subsetneq \cdots$$

と、その和集合 $L_\infty = \bigcup_{k \geq 1} L_k$ を含むとする。このとき $\mathcal{C}$ は正例データから極限同定できない。

証明. 学習器 $\mathcal{A}$ が $\mathcal{C}$ のすべての言語を同定すると仮定する。 $\mathcal{A}$ が無限に多くの異なる仮説言語を出力する L_∞ のテキストを構成する。 L_∞ の列挙を $v_1, v_2, \dots$ とする。有限接頭辞 σ_s が構成され、その内容がある L_{k_s} に含まれていると仮定する。 σ_s の後を L_{k_s} のテキストの要素で続ける。この無限継続は L_{k_s} のテキストなので、ある有限延長の時点で、学習器は言語が L_{k_s} である仮説を出力しなければならない。その後、 $L_{k_s+1} \setminus L_{k_s}$ の要素を一つ追加し、 v_s がまだ現れていなければそれも追加する。新しい有限内容はある後続の $L_{k_{s+1}}$ に含まれ、同じ構成を反復できる。

各 v_s は最終的に現れるため、得られる列は L_∞ のテキストである。しかし選んだ段階で、学習器は真に増大する近似言語 L_{k_s} を出力するので、このテキスト上で意味論的に収束できない。これは L_∞ を同定するという仮定に反する。□

$$L_* := \{a^n b^n \mid n \geq 1\}, \quad L_k := \{a^n b^n \mid 1 \leq n \leq k\}$$

とおく。これらの言語はすべて、ファンアウトーの二分・線形・非消去作業形 MCFG 表示をもつ。まず、極限言語を、任意のアリティ上界について一つの固定観測ファイバーに入れる。

補題 8.3 (極限言語は粗い包絡準同型に関して代入可能である). h_* を a^*b^* の標準 DFA の遷移準同型とする。このとき L_* は、すべての $f \geq 1$ に対して (f, h_*) -タプル代入可能である。

証明. 任意のアリティ d について条件を証明する。タプル $\vec{x}, \vec{y} \in (\Sigma^*)^d$ が同じ成分別 h_* -型をもち、受理文コンテキスト E を共有するとする。したがって、ある $m, n \geq 1$ に対して $E[\vec{x}] = a^n b^n$ および $E[\vec{y}] = a^m b^m$ である。 $\vec{x}$ の各成分に現れる a と b の総数をそれぞれ A_x, B_x とし、 A_y, B_y も同様に定める。 E の外側終端記号の寄与は二つの充填で同一なので、二つの受理語を比較すると

$$A_y - A_x = m - n = B_y - B_x$$

を得る。

次に、 $\vec{x}$ を受理する任意の文コンテキスト F を取り、 $F[\vec{x}] = a^N b^N$ とする。成分を一つずつ、同じ h_* -値をもつ成分で置換しても、充填された文全体の遷移準同型は保存される。したがって $F[\vec{y}] \in a^* b^*$ である。その a の総数は $N + (A_y - A_x)$ 、 b の総数は $N + (B_y - B_x)$ であり、上の等式により両者は等しい。この共通値は零にはなりえない。もし $F[\vec{y}] = \varepsilon$ ならば、 F のすべての終端部分と $\vec{y}$ のすべての成分は空である。標準的な $a^* b^*$ ゾーンオートマトンでは、空語以外の語が恒等変換として作用することはないので、成分別 h_* -型の等しさから $\vec{x}$ の全成分も空となり、 $F[\vec{x}] \in L_*$ に反する。ゆえに $F[\vec{y}] \in L_*$ である。逆向きも対称的に成り立つので、タプル分布は等しい。□

補題 8.4 (有限近似は代入可能にできる). 任意の $k \geq 1$ と $f \geq 1$ に対し、 L_k が (f, h_k) -タプル代入可能となる明示的有限モノイド準同型 h_k が存在する。さらに、ある準同型 h によって L_k が $(1, h)$ -タプル代入可能になるならば、値 $h(a^i b^i)$, $1 \leq i \leq k$, は相異なる。とくに $|\text{im}(h)| \geq k$ である。

証明. 存在については、 h_k を正則言語 L_k の構文準同型とすればよい。アリティ d の二つのタプル $\vec{x}, \vec{y}$ について、各成分で $h_k(x_i) = h_k(y_i)$ が成り立つならば、各置換は L_k に関して構文的に同値な文字列による置換なので、任意の周囲の文コンテキストにおいて、成分を一つずつ置換しても L_k への所属は保存される。したがってすべての d に対して $\mathcal{D}_{L_k}^{(d)}(\vec{x}) = \mathcal{D}_{L_k}^{(d)}(\vec{y})$ であり、 (f, h_k) -代入可能性の含意は直ちに従う。

下界について、 $1 \leq i < j \leq k$ を固定する。語 $x_i = a^i b^i$ と $x_j = a^j b^j$ は、いずれも L_k に属するので、空の両側部分をもつコンテキスト $(\varepsilon, \varepsilon)$ を共有する。しかし、それらの分布は異なる。 (a^{k-i}, b^{k-i}) は x_i を受理し、 $a^k b^k \in L_k$ を生成するが、 x_j を $a^{k-i+j} b^{k-i+j} \notin L_k$ へ送る。したがって $h(x_i) = h(x_j)$ ならば、 $(1, h)$ -代入可能性の含意は破れる。ゆえに $h(a^i b^i)$, $1 \leq i \leq k$, はすべて相異なる。□

命題 8.5 (分離鎖は一つの固定ファイバーには入らない). 任意の固定有限準同型 h に対し、言語 L_k のうち $(1, h)$ -タプル代入可能となるものは有限個しかない。より正確には、 L_k が $(1, h)$ -タプル代入可能ならば $k \leq |\text{im}(h)|$ である。

証明. これは補題 8.4 の下界そのものである。固定 h に対して $\text{im}(h)$ は有限なので、起こりうるのは $k \leq |\text{im}(h)|$ の場合に限られる。したがって、以下で用いる超有限鎖は、必然的にますます細かい観測ファイバーの間を移動する。これは固定 h に対する学習可能性定理と矛盾しない。□

定理 8.6 (助言なしの場合の非同定可能性). 任意の固定 $f \geq 1$ に対し、助言なしクラス $\mathcal{C}_{f, \bullet}^{\text{mcf}}$ は正例データから極限同定できない。

証明. 補題 8.3 により $L_* \in \mathcal{C}_{f, h_*}^{\text{mcf}}$ であり、補題 8.4 により、各 L_k はある明示的有限準同型 h_k に対して $L_k \in \mathcal{C}_{f, h_k}^{\text{mcf}}$ である。したがって助言なし和集合は $L_1 \subsetneq L_2 \subsetneq \dots$ とその和集合 L_* を含む。補題 8.2 を適用すればよい。□

この定理は、系 6.10 と併せて読むべきである。固定有限観測準同型は、一つの学習可能なファイバーを選択する。ファイバーが与えられず、対象が任意の有限準同型を用いてよいならば、和集合クラスは超有限鎖を含み、正例データだけから正しい有限観測インターフェースを決定することはできない。

定義 8.7 (観測サイズ有界和集合). 有限アルファベット Σ 、ファンアウト上界 $f \geq 1$ 、および $k \geq 1$ を固定する。

$$\mathcal{C}_{f, \leq k}^{\text{mcf}} := \bigcup_h \mathcal{C}_{f, h}^{\text{mcf}}$$

と定義する。ここで和集合は、 $|M| \leq k$ を満たすすべての明示的有限モノイド準同型 $h : \Sigma^* \rightarrow M$ にわたって取る。

補題 8.8 (観測の同型不変性). $\varphi : M \rightarrow M'$ が単射モノイド準同型ならば、ある言語が (f, h) -タプル代入可能であることと、 $(f, \varphi \circ h)$ -タプル代入可能であることは同値である。したがって $\mathcal{C}_{f, h}^{\text{mcf}} = \mathcal{C}_{f, \varphi \circ h}^{\text{mcf}}$ である。

証明. 定義 3.14 では、 h は成分別の値の等しさを通じてのみ用いられる。 φ は単射なので、 $h(u) = h(v)$ と $\varphi(h(u)) = \varphi(h(v))$ は同値である。所属条件の文法理論的部分は変化しない。□

定理 8.9 (観測サイズを有界にすると同定可能性が回復する). 任意の固定有限アルファベット Σ 、ファンアウト上界 $f \geq 1$ 、および $k \geq 1$ に対し、

$$\mathcal{C}_{f, \leq k}^{\text{mcf}} \subseteq \mathcal{C}_{f, H}^{\text{mcf}}$$

を満たす明示的有限モノイド準同型 $H = H_{\Sigma, k} : \Sigma^* \rightarrow M_H$ が存在する。したがって、パラメータ (f, H) をもつ正準学習器は、 $\mathcal{C}_{f, \leq k}^{\text{mcf}}$ を正例データから極限同定する。

証明. 同型を除けば、濃度が高々 k のモノイドは有限個しかない。その明示的代表を $M_1, \dots, M_t$ とする。 Σ^* は自由モノイドなので、準同型 $\Sigma^* \rightarrow M_j$ は任意の写像 $\Sigma \rightarrow M_j$ によって一意に決定される。したがって、代表への準同型は高々 $tk^{|\Sigma|}$ 個である。それらを $h_i : \Sigma^* \rightarrow M_{j_i}$, $1 \leq i \leq r$, と列挙し、

$$M_H := M_{j_1} \times \dots \times M_{j_r}, \quad H := (h_1, \dots, h_r) : \Sigma^* \rightarrow M_H$$

と定める。ただし積は成分ごとにとる。 M_H の乗法表と各文字 $a \in \Sigma$ の値 $H(a)$ は因子の表から計算できるので、 H は明示的である。

$|M| \leq k$ を満たす任意の明示的準同型 $h : \Sigma^* \rightarrow M$ を取る。ある代表への同型 $\varphi : M \rightarrow M_j$ を選ぶ。このとき $\varphi \circ h$ は上の列挙に現れ、たとえば $\varphi \circ h = h_i$ と書ける。準同型

$$\pi := \varphi^{-1} \circ \text{pr}_i : M_H \rightarrow M$$

は $\pi \circ H = h$ を満たす。したがって $h \preceq H$ であり、命題 3.9 から $\mathcal{C}_{f, h}^{\text{mcf}} \subseteq \mathcal{C}_{f, H}^{\text{mcf}}$ を得る。 $|M| \leq k$ のすべての h について和集合を取れば、 $\mathcal{C}_{f, \leq k}^{\text{mcf}} \subseteq \mathcal{C}_{f, H}^{\text{mcf}}$ である。系 6.10 により、固定準同型 H に対する正準学習器は $\mathcal{C}_{f, H}^{\text{mcf}}$ を同定する。極限同定は対象と言語テキストに関する全称命題なので、同じ学習器が部分クラス $\mathcal{C}_{f, \leq k}^{\text{mcf}}$ も同定する。□

注意 8.10 (実用的サイズではなく存在を述べる定理). 普遍直積準同型 $H_{\Sigma, k}$ は非常に巨大になりうる。この定理は、固定された各 (Σ, f, k) に対する同定可能性を述べるものであり、この直積が実用的な表示であることや、そのサイズが k の多項式であることを主張しない。その役割は、助言なし和集合の失敗が、観測サイズが非有界になったときに初めて生じることを示す点にある。

注意 8.11 (有界観測助言と非有界観測助言). 定理 8.9 は、定理 8.6 と矛盾しない。前者は、失敗の原因が観測モノイドの非有界性にあることを示している。補題 8.4 により、有限近似 $L_k = \{a^n b^n \mid 1 \leq n \leq k\}$ が $(1, h)$ -タプル代入可能となるためには $|\text{im}(h)| \geq k$ が必要である。し

たがって、助言なし定理で用いた超有限鎖は、観測サイズが固定されたどのスライスにも入らない。 $\mathcal{C}_{f,\bullet}^{\text{mcf}} = \bigcup_{k \geq 1} \mathcal{C}_{f,\leq k}^{\text{mcf}}$ であるから、正例データ同定可能性は各有界スライスでは成り立つが、その増大和集合では保存されない。これは同定可能性に関する主張であって、 k や Σ に関して一様な効率性を主張するものではない。固定された (Σ, k) に対して直積準同型 $H_{\Sigma,k}$ は固定されるが、その大きさは非常に巨大になりうる。

8.1 無限メンバー核

言語 $L \subseteq \Sigma^*$ に対し、そのアリティーのメンバー核を

$$\text{MK}_1(L) := \{\mathcal{D}_L^{(1)}(w) \mid w \in L\}$$

と定義する。これはすべての残余分布についての有限核条件ではなく、 L 自身の要素である文字列の分布だけを記録するものである。

定理 8.12 (無限メンバー核による排除). $L \subseteq \Sigma^*$ とする。 $\text{MK}_1(L)$ が無限ならば、任意の $f \geq 1$ に対して

$$L \notin \bigcup_h \mathcal{C}_{f,h}^{\text{mcf}}$$

である。ここで和集合は、すべての明示的有限モノイド準同型 $h : \Sigma^* \rightarrow M$ にわたって取る。

証明. 背理法により、ある明示的有限モノイド準同型 $h : \Sigma^* \rightarrow M$ に対して $L \in \mathcal{C}_{f,h}^{\text{mcf}}$ であると仮定する。 $w, w' \in L$ が $h(w) = h(w')$ を満たすとする。恒等文コンテキスト $\square_1$ は w, w' の両方を受理する。 $f \geq 1$ であり、 L は (f, h) -タプル代入可能なので、アリティーの含意から

$$\mathcal{D}_L^{(1)}(w) = \mathcal{D}_L^{(1)}(w')$$

を得る。したがって、要素語 $w \in L$ の分布 $\mathcal{D}_L^{(1)}(w)$ は、有限値 $h(w) \in M$ によって決定される。ゆえに異なるメンバー分布は高々 $|M|$ 個しか存在せず、 $\text{MK}_1(L)$ が無限であることに反する。 $\square$

系 8.13 (傾き和言語はあらゆる有限観測の外にある). 任意の $f \geq 1$ に対し、

$$L_{\text{slope}} = \{a^n b^n \mid n \geq 1\} \cup \{a^n b^{2n} \mid n \geq 1\}$$

は

$$L_{\text{slope}} \notin \bigcup_h \mathcal{C}_{f,h}^{\text{mcf}}$$

を満たす。

傾き和言語は二つの文脈自由言語の和であるから、それ自身も文脈自由である。したがって、この障害は高いファンアウトやコピー能力によって生じるものではない。

証明. 定理 8.12 により、アリティーのメンバー核が無限であることを示せば十分である。 $n \geq 1$ に対して

$$w_n = a^n b^n \in L_{\text{slope}}, \quad C_n = \square_1 b^n$$

とおく。このとき $C_n[w_n] = a^n b^{2n} \in L_{\text{slope}}$ である。一方、 $m \neq n$ ならば $C_n[w_m] = a^m b^{m+n}$ である。この語は $\{a^r b^r \mid r \geq 1\}$ には属さない。所属するには $m + n = m$ が必要だからである。また $\{a^r b^{2r} \mid r \geq 1\}$ にも属さない。所属するには $m + n = 2m$ 、したがって $n = m$ が必要であり、仮定に反する。ゆえに

$$C_n \in \mathcal{D}_{L_{\text{slope}}}^{(1)}(w_n) \quad \text{だが} \quad C_n \notin \mathcal{D}_{L_{\text{slope}}}^{(1)}(w_m) \quad (m \neq n).$$

メンバー分布は互いに異なるので、定理 8.12 が適用できる。 $\square$

命題 8.14 (コピー言語はあらゆる有限観測の外にある)。

$$L_{\text{copy}} = \{ww \mid w \in \{a, b\}^+\}$$

とする。このとき任意の $f \geq 1$ に対して

$$L_{\text{copy}} \notin \bigcup_h \mathcal{C}_{f,h}^{\text{mcf}}$$

である。これは、 L_{copy} が標準的なファンアウト二の線形多重文脈自由言語であるにもかかわらず成り立つ。

証明. ファンアウト二の上界は、よく知られた MCFG のコピー構成による。たとえばランクーの線形規則 $A \rightarrow (ax^1, ax^2)(A)$ 、 $A \rightarrow (bx^1, bx^2)(A)$ 、 $A \rightarrow (a, a)$ 、 $A \rightarrow (b, b)$ を用い、最後に上位の連結規則を置けばよい。この上界はここでは背景にすぎず、以下の排除はどの表示にも依存しない。

アリティのメンバー核が無限であることを示す。 $n \geq 1$ に対し

$$x_n = a^n b, \quad z_n = x_n x_n \in L_{\text{copy}}, \quad C_n = \square_1 z_n$$

とおく。このとき $C_n[z_n] = z_n z_n \in L_{\text{copy}}$ である。 $m \neq n$ ならば

$$C_n[z_m] = z_m z_m = x_m x_m x_n x_n$$

は平方語ではないことを示す。実際、

$$x_m x_m x_n x_n = a^m b a^m b a^n b a^n b$$

と書き、全長の半分の $H = m + n + 2$ とする。平方語では、位置が H だけ離れた文字は一致しなければならない。四つの b の位置は

$$m + 1, \quad 2m + 2, \quad 2m + n + 3, \quad 2m + 2n + 4$$

である。 $m < n$ の場合、二番目の位置 $2m + 2$ は前半にあり、

$$(2m + 2) + H = 3m + n + 4$$

は三番目と四番目の b の間に厳密に位置するので、そこにある文字は a である。これは平方語の条件に反する。 $m > n$ の場合、二番目の位置は後半にあり、そこから H を引くと

$$(2m + 2) - H = m - n$$

となる。これは最初の b より前、すなわち再び a の位置にあるため、やはり平方語の条件に反する。

したがって

$$C_n \in \mathcal{D}_{L_{\text{copy}}}^{(1)}(z_n) \quad \text{だが} \quad C_n \notin \mathcal{D}_{L_{\text{copy}}}^{(1)}(z_m) \quad (m \neq n).$$

メンバー分布 $\mathcal{D}_{L_{\text{copy}}}^{(1)}(z_n)$ は互いに異なる。定理 8.12 により、 L_{copy} はすべての有限観測クラスから排除される。 $\square$

注意 8.15. 傾き和言語の例は、この障害が単に正則包絡の選び方の悪さによるものではないことを示す。その和言語を安全にする有限観測準同型は存在しない。コピー言語の例は別の境界を示している。標準的なファンアウト二の $MCFL$ であっても、すべての有限観測仮定を破りうる。

9 分布学習との比較

固定観測条件は、分布的代入可能性の型付き版とみなすのが最も適切である。共有コンテキストが分布の等しさを強制する前に、成分ごとの有限モノイド型の一致を要求することで、型なしの発

火条件を弱めている。

■**多次元代入可能性との三つの相違。** 本論文の条件は、発想上は Yoshinaka の多次元代入可能性に近いが、それを直接置き換えることを意図したものではない。重要な相違は三つある。

第一に、置換の発火条件が型付きである。型なしの設定では、受理する多次元コンテキストを共有するだけで分布の等しさが要求される。ここでは、受理する名前付き文コンテキストを共有しても、成分別有限観測 $h^{(d)}$ が一致した場合に限って分布の等しさが要求される。したがって有限準同型は、分布的置換に対する正則または有限状態のガードとして働く。

第二に、ここで用いるコンテキストは、文法内部の多次元コンテキストではなく、文レベルの名前付き穴コンテキストである。これは、タプルが完全な文字列の中でどのように露出するかを記録し、名前付き成分は文中の任意の順序で現れてよい。この設計は、完全な導出インターフェースを保存するより意図的に弱い。学習器は正例文字列内の具体的出現を観測し、欠けた露出コンテキストを特徴標本によって補う。

第三に、本結果は助言相対的である。有限準同型 h は学習開始前に固定され、テキストから推論されない。したがって定理が同定するのは固定観測ファイバー $\mathcal{C}_{f,h}^{\text{mcf}}$ であり、MCFL 全体でも、すべての有限観測にわたる和集合でもない。

	多次元代入可能性	固定観測タプル代入可能性
発火条件	多次元コンテキストの共有	名前付き文コンテキストの共有と等しい h -型
型情報	なし、またはコンテキスト体系に暗黙に含まれる	あらかじめ固定された明示的有限モノイド観測
学習対象	分布的に制限された MCFL クラス	固定された助言相対的ファイバー $\mathcal{C}_{f,h}^{\text{mcf}}$
主な制約	コンテキスト条件が置換を直接制御する	観測 h は正例データから学習されない

第 4 節の例は、有限ガードが有用である理由を示している。ブロック同期言語では、文コンテキストを共有するだけでは粗すぎる。タプルは同じ外側位置に現れながら、異なる正則ゾーンをまたぐことがある。正則包絡の遷移準同型は、このような危険な置換を防ぐ一方、等長制約そのものは正例データから分布的に学習される。

$\mathcal{Y}_f^{\text{nam}}$ を、ファンアウトが高々 f で、型なし名前付き文代入可能性条件を満たす MCFL のクラスとする。すなわち、任意の $1 \leq d \leq f$ について、二つのアリティ d のタプルが受理する名前付き文コンテキストを共有するならば、それらを受理する名前付き文コンテキストの分布は等しいものとする。

命題 9.1 (型なし名前付き代入可能性は任意の固定観測を含意する). 任意の明示的有限準同型 h と任意の $f \geq 1$ に対して

$$\mathcal{Y}_f^{\text{nam}} \subseteq \mathcal{C}_{f,h}^{\text{mcf}}$$

である。

証明. 固定 h の含意は、型なし名前付き条件と同じ結論をもち、前提に $h^{(d)}(\vec{x}) = h^{(d)}(\vec{y})$ を追加

ただけである。したがって、型なし名前付き代入可能言語は自動的に (f, h) -タプル代入可能である。同じファンアウト表示が、所属条件の文法理論的部分を証言する。□

この包含は真包含になりうる。 $L_3 = \{a^n b^n c^n \mid n \geq 1\}$ とし、 h_R を $R = a^* b^* c^*$ の標準 DFA の遷移準同型とする。命題 4.6 により、 L_3 はファンアウト二の作業形表示をもつ。また、すべての $f \geq 2$ に対して (f, h_R) -タプル代入可能でもある。実際、受理コンテキストを共有すると三文字の個数に共通のずれが固定され、 h_R -型の等しさによって、その後のすべての充填がブロックゾーン $a^* b^* c^*$ 内に保たれる。したがって、一方のタプルを受理する後続コンテキストはすべて他方も受理し、逆も成り立つ。

一方、 L_3 は型なし名前付き代入可能ではない。アリティ二のタプル

$$\vec{x} = (a, c), \quad \vec{y} = (a^2 b, c^2)$$

は、受理コンテキスト $E = \square_1 b \square_2$ を共有する。実際、 $E[\vec{x}] = abc$ かつ $E[\vec{y}] = a^2 b^2 c^2$ である。しかし $F = \square_1 abb \square_2 c$ とすると、 $F[\vec{x}] = a^2 b^2 c^2 \in L_3$ である一方、 $F[\vec{y}] = aababbccc \notin L_3$ である。したがって、型付き固定観測条件は、対応する型なし名前付き条件を真に拡張する。

Yoshinaka の順序付き多次元コンテキストとの比較は、文字どおりの包含関係ではない。順序付き穴と名前付き文穴は異なるコンテキスト幾何を検査するからである。本形式体系は意図的に名前付き穴を用いる。MCFG の成分は、周囲の文の中で置換された順序に露出しうるからである。固定準同型は、共有される全コンテキスト分布の型なし大域的一致を要求する代わりに、露出した成分へ有限型規律を与える。

10 結論

任意の固定ファンアウト上界 f と固定された明示的有限モノイド観測 h に対して、クラス $\mathcal{C}_{f,h}^{\text{mcf}}$ は、正準的なタプル列挙学習器により正例データから極限同定可能である。この構成が保存するのは、成分ごとの出力型と観測タプル値である。成分配置は具体的な証人付き分割から復元され、代入は実際に共有された文コンテキストによって保護される。再構成は言語レベルで厳密である一方、観測準同型と意味論的代入可能性の仮定は外部から与えられる条件として残る。

観測パラメータには明確な質的境界がある。一つの固定ファイバーは学習可能であり、モノイドサイズに固定上界があるすべてのファイバーの和集合も、一つの有限直積準同型を通じて学習可能である。しかし、すべての有限観測にわたる非有界和集合は、正例データから同定できない。これとは独立に、無限メンバー核基準は、要素のコンテキスト分布を有限個の観測値に圧縮できない言語を排除する。

得られる領域は非自明であるが真に狭い。標準的な三ブロック同期、並列同期、交差直列同期の例を含む一方、文脈自由な傾き和言語とファンアウト二のコピー言語は、すべての有限観測ファイバーの外にある。したがって固定有限モノイド助言は、MCFL 全体を別の形で表示するのではなく、その内部に真正の学習可能領域を切り出す。

付録 A 意味論的仮定の非実効性

同定定理は、意味論的な (f, h) -タプル代入可能性の仮定を条件としている。本付録では、この仮定を実効的に検査可能な構文論的付帯条件として扱わない理由を記す。

定理 付録 A.1 (任意の固定有限観測に対する非決定可能性). Σ を $|\Sigma| \geq 2$ を満たす固定有限アルファベットとし、 $h : \Sigma^* \rightarrow M$ を有限モノイドへの任意の固定された明示的準同型とする。このとき、 Σ 上の文脈自由文法が与えられたとき、その言語が $(1, h)$ -タプル代入可能であるかを判定する問題は決定不能である。任意の固定 $f \geq 1$ に対する (f, h) -タプル代入可能性についても同様である。さらに、肯定例の集合は *co-r.e.*-完全である。これは標準的な実効符号化の下で Π_1^0 -完全であることと同値である。

証明. 文脈自由文法の普遍性問題は、標準的な実効符号化の下で Π_1^0 -完全である [8]。まず、固定アルファベット Σ 上でも同じ分類が成り立つことを確認する。任意の有限アルファベット Γ 上の CFG G が与えられたとする。相異なる文字 $a, b \in \Sigma$ を選び、単射な固定長符号 $c : \Gamma \rightarrow \{a, b\}^m$ を取り、 Γ^* 上の準同型へ拡張する。言語 $C := c(\Gamma)^*$ は正則であり、 Σ 上の言語

$$U_G := (\Sigma^* \setminus C) \cup c(L(G))$$

を生成する CFG を実効的に構成できる。 c は単射なので、

$$U_G = \Sigma^* \iff L(G) = \Gamma^*$$

である。したがって普遍性問題は、濃度が少なくとも二である任意の固定アルファベット上で Π_1^0 -困難である。また、語を列挙して CFG 所属を判定すれば非普遍性を再帰的に列挙できるので、普遍性問題は Π_1^0 に属する。ゆえに固定アルファベット上の普遍性問題は Π_1^0 -完全である。非単項という条件は本質的である。固定正則言語との等価性に関する Hopcroft の特徴づけから、CFG 普遍性は単項アルファベット上では決定可能であり、すべての固定された非単項アルファベット上では決定不能であることが従う [10]。

次に、固定アルファベット上の CFG 普遍性を意味論的仮定へ帰着する。 G_0 を Σ 上の CFG とする。 M は有限なので、 $|\Sigma|^N > |M|$ を満たす整数 N を選ぶ。長さ N の語の中には、 $h(X) = h(Y)$ を満たす相異なる語 $X, Y \in \Sigma^N$ が存在する。長さが等しく相異なることから、 $X\Sigma^* \cap Y\Sigma^* = \emptyset$ である。

非空語 $\beta \in \Sigma^+$ を固定する。 Σ 上の文法 G_0 が与えられたとき、

$$L'(G_0) := (\Sigma^* \setminus \beta\Sigma^*) \cup \beta L(G_0)$$

と定義する。 $L(G_0) = \Sigma^*$ ならば $L'(G_0) = \Sigma^*$ である。一方、 $z \notin L(G_0)$ ならば $\beta z \notin L'(G_0)$ である。また $\varepsilon \in L'(G_0)$ である。

像部分モノイドを $H_0 = h(\Sigma^*)$ とし、

$$S := h(Y)H_0, \quad K_{\text{pos}} := h^{-1}(S)$$

とおく。最後に

$$K(G_0) := (K_{\text{pos}} \setminus Y\Sigma^*) \cup YL'(G_0)$$

と定める。 K_{pos} と $Y\Sigma^*$ は正則であり、 $YL'(G_0)$ は文脈自由なので、言語 $K(G_0)$ は実効的に文脈自由である。

$L(G_0) = \Sigma^*$ ならば $L'(G_0) = \Sigma^*$ である。 $Y\Sigma^* \subseteq K_{\text{pos}}$ なので

$$K(G_0) = K_{\text{pos}} = h^{-1}(S)$$

を得る。したがって $K(G_0)$ への所属は、語全体の h -値によって決定される。二つのタプルが同じ成分別 h -型をもつならば、任意の文コンテキストにおける二つの充填は語全体として同じ h -値をもつ。ゆえに $K(G_0)$ に関する受理コンテキストは等しく、 $K(G_0)$ はすべての $f \geq 1$ に対して (f, h) -タプル代入可能である。

逆に、 $L(G_0) \neq \Sigma^*$ とし、 $z \notin L(G_0)$ を選ぶ。

$$u := X, \quad v := Y, \quad E = \square_1, \quad F = \square_1 \beta z$$

とおく。このとき $h(u) = h(v)$ である。また $X\Sigma^* \cap Y\Sigma^* = \emptyset$ なので $E[u] = X \in K_{\text{pos}} \setminus Y\Sigma^*$ であり、 $\varepsilon \in L'(G_0)$ なので $E[v] = Y \in YL'(G_0)$ である。さらに $h(X\beta z) = h(Y\beta z) \in h(Y)H_0 = S$ であり、 $X\beta z \notin Y\Sigma^*$ なので、 $F[u] = X\beta z \in K(G_0)$ である。一方、 $F[v] = Y\beta z$ は取り除かれた円筒集合 $Y\Sigma^*$ に属し、 $\beta z \notin L'(G_0)$ なので $YL'(G_0)$ によって復元されない。したがって $F[v] \notin K(G_0)$ である。

ゆえに u, v は同じ h -型をもち、受理コンテキスト E を共有するが、コンテキスト F はそれらの分布を分離する。したがって出力言語は $(1, h)$ -タプル代入可能ではない。これにより、CFG 普遍性問題から意味論的仮定への多対一帰着が得られる。同じアリティの証人は、すべての $f \geq 1$ に対する (f, h) -タプル代入可能性も否定する。

最後に、 (f, h) -タプル代入可能性の失敗は、有限タプルとコンテキストを列挙し、有限個の文法所属条件を検査することで半決定可能である。したがって肯定例は co-r.e. であり、上の普遍性帰着と合わせると co-r.e.-完全、すなわち標準的な実効符号化の下で Π_1^0 -完全である。□

注意 付録 A.2 (仮定が意味論的である理由). 上の定理は、注意 3.16 を精密化する。学習器はすべての有限正例標本上で全域的に定義され、整合的であるが、その厳密性の主張は必然的に条件付きである。ファンアウト一であっても、また文字上で単射な固定観測準同型であっても、意味論的代入可能性の仮定を文法表示から判定手続きによって検証することはできない。半決定可能なのは、上の証明で示した有限証人による失敗だけである。この定理は意味論的な CFG 入力問題について述べている。厳密に ε -なしの作業形表示版は、標識文字を用いる設定では同じ一標識構成によって処理できるが、ここでの任意の h に対する構成は、意味論的仮定に関する結果としてのみ用いる。

参考文献

- [1] D. Angluin. Inductive inference of formal languages from positive data. *Information and Control*, 45(2):117–135, 1980.
- [2] D. Angluin. Learning regular sets from queries and counterexamples. *Information and Computation*, 75(2):87–106, 1987.
- [3] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007.
- [4] A. Clark and R. Yoshinaka. Distributional learning of parallel multiple context-free grammars. *Machine Learning*, 96(1–2):5–31, 2014.

- [5] A. Clark and R. Yoshinaka. Distributional learning of context-free and multiple context-free grammars. In *Topics in Grammatical Inference*, pp. 143–172. Springer, 2016.
- [6] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27(2):125–138, 1997.
- [7] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars*. Cambridge University Press, 2010.
- [8] M. Domaratzki, A. Okhotin, and J. Shallit. Enumeration of context-free languages and related structures. *Journal of Automata, Languages and Combinatorics*, 12(1–2):79–95, 2007.
- [9] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474, 1967.
- [10] J. E. Hopcroft. On the equivalence and containment problems for context-free languages. *Mathematical Systems Theory*, 3(2):119–124, 1969. doi:10.1007/BF01746517.
- [11] L. Kallmeyer. *Parsing Beyond Context-Free Grammars*. Springer, Heidelberg, 2010.
- [12] M. Kanazawa. *Learnable Classes of Categorical Grammars*. CSLI Publications, Stanford, 1998.
- [13] T. Kuriyama. Distributional learning of context-free languages under fixed finite-monoid typing. arXiv:1409.6247v4 [cs.FL], 2026.
- [14] F. Lehner and C. Lindorfer. Comparing consecutive letter counts in multiple context-free languages. arXiv:2002.08236 [cs.FL], 2020.
- [15] S. M. Shieber. Evidence against the context-freeness of natural language. *Linguistics and Philosophy*, 8(3):333–343, 1985.
- [16] J.-E. Pin. *Varieties of Formal Languages*. North Oxford Academic, London, and Plenum, New York, 1986.
- [17] H. Seki, T. Matsumura, M. Fujii, and T. Kasami. On multiple context-free grammars. *Theoretical Computer Science*, 88(2):191–229, 1991.
- [18] K. Vijay-Shanker, D. J. Weir, and A. K. Joshi. Characterizing structural descriptions produced by various grammatical formalisms. In *Proceedings of the 25th Annual Meeting of the Association for Computational Linguistics*, pp. 104–111, 1987.
- [19] D. J. Weir. *Characterizing Mildly Context-Sensitive Grammar Formalisms*. Ph.D. thesis, University of Pennsylvania, 1988.
- [20] R. Yoshinaka. Identification in the limit of k, ℓ -substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications*, LNCS 5278, pp. 266–279. Springer, 2008.
- [21] R. Yoshinaka. Learning mildly context-sensitive languages with multidimensional substitutability from positive data. In *Algorithmic Learning Theory*, LNCS 5809, pp. 278–292. Springer, 2009.
- [22] R. Yoshinaka. Efficient learning of multiple context-free languages with multidimensional substitutability from positive data. *Theoretical Computer Science*, 412(19):1821–1831,

2011.